VLM hiểu cảnh giao thông đa camera trên DriveLM-nuScenes

Báo cáo giai đoạn 1 (perception) · 11/11/2026 · Tran Thanh Dat · mã nguồn: `drivelm-perception-vlm` · máy: RTX 5060 Ti 16 GB, Ryzen 7 7800X3D, 32 GB RAM

Tóm tắt. Fine-tune Qwen3-VL-2B bằng LoRA trên 40.000 câu hỏi perception của DriveLM-nuScenes, với 6 ảnh camera riêng có tên camera (R1), trong khoảng 4 giờ trên một GPU 16 GB. Mọi câu trả lời được kiểm chứng bằng box 3D của nuScenes; mọi so sánh giữa hai mô hình được kiểm tra bằng bootstrap ghép cặp trên cùng các scene. Kết quả chính:

- **R1 định vị được vật thể quan trọng:** P1 F1 55,0% ở ngưỡng 100 px (3 seed: 54,2–55,0); 89,7% thẻ rơi vào một box nuScenes. Mô hình gốc đạt 0 khi zero-shot và 3,3 khi được xem 2 ví dụ mẫu: đã viết đúng định dạng nhưng chưa định vị được. Bản LoRA không ảnh đạt 19,7.
- **Ảnh đóng góp +19 đến +35 điểm** so với cùng công thức train nhưng không có ảnh, ở P1, P2o, P3, P5, P6. Thẻ bịa giảm từ 19,0% xuống 5,4%.
- **R1 dùng ảnh của chính camera được hỏi:** chỉ cho xem CAM_FRONT thì ở các câu hỏi về camera khác, P1 về 0 và P2o, P3, P5, P6 tụt 18–44 điểm, về gần mức của bản không ảnh (P3 còn thấp hơn).
- **Câu hỏi "xe có đang rẽ không" (P2) là giới hạn của ảnh tĩnh:** R1 gần như không nhận ra câu rẽ. Oracle dùng hướng quay thật trong 1 giây quá khứ đạt balanced accuracy 75% so với 34%: đây là lý do định lượng cho giai đoạn 2 (nhiều khung hình).
- **Cũng quan trọng là những gì chưa chứng minh được:** P4; thêm dữ liệu (10k so với 40k khi cùng số bước); R1 so với ảnh lưới ở các câu ngoài P3.

1. Bài toán và cách làm

Dữ liệu. DriveLM-nuScenes v1.1 kèm metadata nuScenes v1.0-trainval: 162.480 câu perception trên 4.072 keyframe, 696 scene; tách theo scene thành 605 scene train (141.808 câu) và 91 scene val (20.672 câu). Bảy loại câu được chấm: P1 vật thể quan trọng (trả lời bằng thẻ <c,CAM,x,y>), P2 vật thể có đang rẽ không, P2o trạng thái quan sát, P3 loại vật thể, P4 có/không theo vùng, P5 các loại vật thể theo vùng, P6 trạng thái vật thể theo vùng. Tập val cố định gồm 700 câu, 100 câu mỗi loại; P2 còn được chấm trên toàn bộ 1.153 câu val vì câu rẽ hiếm.

Kiểm chứng nhãn. Mỗi thẻ của DriveLM được nối với box nuScenes chiếu xuống ảnh (99,1% nối được). Nhãn DriveLM khớp nuScenes: trạng thái 89,7%, loại vật thể 94,3%, P4 93,7%. Đèn và biển báo không có box trong nuScenes, nên không được nối.

Mô hình. Qwen3-VL-2B-Instruct, LoRA r = 16 trên attention và MLP của phần ngôn ngữ (17,4 triệu tham số, 0,81%). Mỗi camera vào mô hình khoảng 448 × 224 px (98 token), tổng 588 token ảnh. Train 1 epoch: batch hiệu dụng 16, lr 2e-4 cosine, bf16, loss chỉ trên câu trả lời, tắt ngẫu nhiên 15% camera không được hỏi tới. 2.500 bước, khoảng 4,2 giờ.

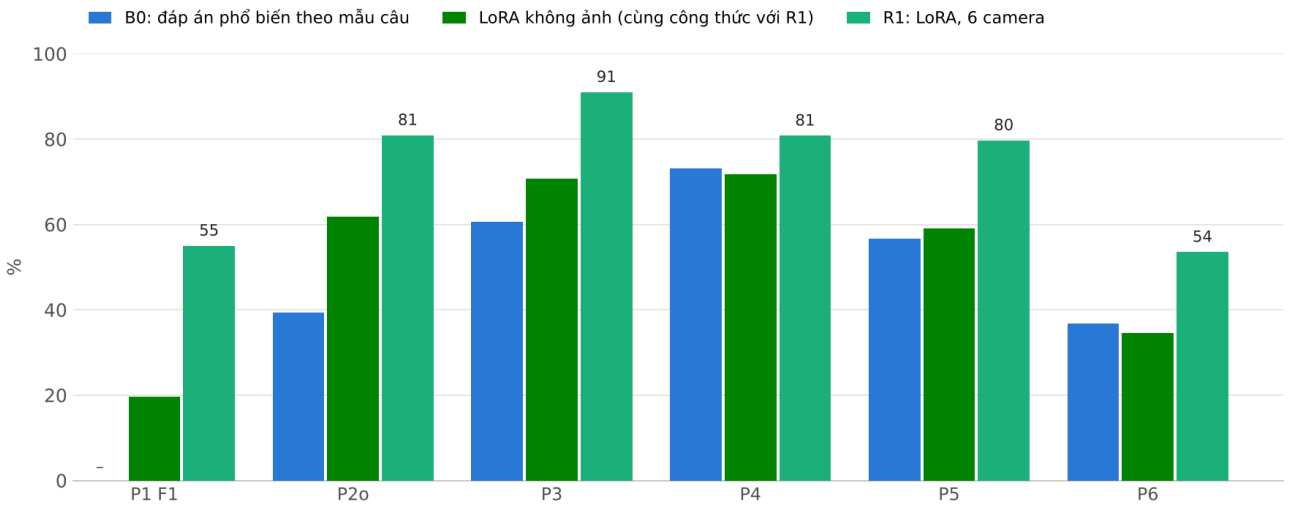
Chấm điểm. P1: F1 sau ghép Hungarian ở ngưỡng 50/100/200 px; thẻ bịa = không nằm trong box nào, cách box gần nhất hơn 100 px, và không khớp thẻ đáp án nào. P2, P2o, P6: macro-F1; P3: accuracy; P4: balanced accuracy; P5: F1 trên tập loại vật thể. Độ bất định: bootstrap 1.000 lần rút lại *cả scene*; so sánh hai mô hình bằng bootstrap ghép cặp trên cùng các câu hỏi. Bộ chấm được kiểm tra tay trên 100 câu: đúng 99/100, lỗi duy nhất đã sửa.

2. Kết quả chính (700 câu val cố định)

Mô hình	P1 F1	Bịa	P2o	P3	P4	P5	P6	Latency p50	Ghi chú
B0: đáp án phổ biến theo mẫu câu	–	–	39,4	60,7	73,1	56,7	36,9	–	Không nhìn ảnh
B1: SigLIP2 zero-shot, vùng cắt	–	–	37,8	73,0	–	–	–	0,03 s*	Chỉ P2, P2o, P3
B2: Qwen3-VL-2B zero-shot	0,0	–	32,7	68,5	59,3	21,8	8,1	0,46 s	16,7% không đọc được
B2 + 2 ví dụ mẫu (few-shot)	3,3	54,6 %	35,9	60,7	63,0	64,0	13,5	0,21 s	4,6% không đọc được
LoRA không ảnh (cùng công thức)	19,7	19,0 %	61,8	70,8	71,7	59,2	34,6	0,10 s	Tách prior câu hỏi
R1: LoRA, 6 ảnh riêng	**55,0**	5,4%	**80,9**	**91,0**	80,8	**79,7**	**53,6**	0,22 s	Seed 0
R1, seed 1	54,9	4,8%	82,4	89,9	80,0	79,3	55,4	0,23 s	
R1, seed 2	54,2	6,8%	82,2	88,8	81,5	77,1	52,7	0,23 s	
R2: LoRA, 1 ảnh lưới 3×2	54,9	5,7%	79,3	84,3	77,3	76,6	47,0	0,24 s	630 token ảnh

Đơn vị %. P2o, P6: macro-F1; P3: accuracy; P4: balanced accuracy; P5: F1. Latency p50 trên RTX 5060 Ti. * B1 chỉ chạy encoder trên một vùng cắt, không sinh văn bản, nên không so sánh được với các VLM. Khoảng tin cậy 95% theo scene của mỗi ô rộng từ khoảng ±4 (P5) đến ±20 điểm (P6) (ví dụ R1 P5 [75,4; 83,3], P6 [35,6; 76,5]); vì vậy mọi so sánh dưới đây dùng bootstrap ghép cặp.

- **Fine-tune học định vị, không chỉ học định dạng.** Cho mô hình gốc xem 2 câu trả lời mẫu của cùng loại câu hỏi: tỷ lệ không đọc được giảm từ 16,7% xuống 4,6% và P5 tăng từ 21,8 lên 64,0, tức là mô hình đã học được cách trả lời. Nhưng P1 chỉ đạt 3,3, với 54,6% thẻ bịa: biết viết thẻ <c,CAM,x,y> không có nghĩa là chỉ đúng vật thể. Trong 55 điểm P1 của R1, khoảng 20 điểm đạt được cả khi không có ảnh (đoán vị trí hay gặp) và +35 điểm đến từ việc nhìn ảnh (mục 3).
- **Ba seed của R1 lệch nhau tối đa 2,7 điểm** (P6 52,7–55,4; P5 77,1–79,7; P3 88,8–91,0; P1 54,2–55,0), nhỏ hơn nhiều khoảng tin cậy của tập val.



Hình 1. B0, LoRA không ảnh và R1. Khoảng cách xanh lá → xanh ngọc là phần đến từ ảnh; xanh dương → xanh lá là phần học được từ câu hỏi.

3. Phần nào của điểm số đến từ ảnh?

Bản LoRA không ảnh dùng đúng công thức của R1 (40.000 mẫu, 2.500 bước) nhưng bỏ hết ảnh. Hiệu R1 − không ảnh là phần đóng góp của ảnh; hiệu không ảnh − B0 là phần mô hình học được chỉ từ câu chữ.

Chênh lệch, cùng câu hỏi [95% CI]	P1 F1	Bịa	P2o	P3	P4	P5	P6
R1 − không ảnh (phần nhờ ảnh)	**+35,4** [+29,9; +40,9]	**−13,6** [−20,5; −7,5]	**+19,1** [+9,3; +30,2]	**+20,2** [+9,1; +31,0]	+9,1 [−0,6; +19,8]	**+20,6** [+12,4; +28,1]	**+19,0** [+1,8; +31,3]
Không ảnh − B0 (phần nhờ câu hỏi)	–	–	**+22,4** [+10,8; +32,9]	**+10,1** [+3,8; +17,9]	−1,4 [−7,1; +1,4]	+2,5 [−0,6; +5,7]	−2,3 [−7,9; +3,3]
R1 − B0 (tổng)	–	–	**+41,5** [+32,8; +49,4]	**+30,3** [+18,8; +42,2]	+7,7 [−3,8; +20,0]	**+23,0** [+14,4; +30,9]	+16,7 [−2,6; +31,1]

In đậm = khoảng tin cậy không chứa 0. Bootstrap ghép cặp, rút lại scene, 1.000 lần.

- **Ảnh giúp có thật ở 6/7 chỉ số.** Riêng P4 chưa chứng minh được, có thể vì câu có/không theo vùng đã đoán được khá tốt từ mẫu câu (B0 73,1).
- **Chỉ fine-tune trên chữ đã tăng P2o 22 điểm.** Khoảng một nửa mức tăng P2o của R1 so với B0 đến từ cách đặt câu hỏi, không phải từ ảnh. Nếu chỉ so với B0 thì sẽ đánh giá cao vai trò của ảnh.
- **Bản không ảnh vẫn đạt P1 F1 19,7** bằng cách đoán các vị trí hay gặp (ví dụ xe ngay phía trước), nhưng 19% thẻ của nó là bịa.

4. R1 có dùng ảnh của chính camera được hỏi không?

Đánh giá lại checkpoint R1 khi chỉ đưa ảnh CAM_FRONT, rồi tách điểm theo camera mà câu hỏi nhắc tới (27 câu P4 về camera trước, 73 câu về camera khác).

Câu hỏi về 5 camera không phải CAM_FRONT	P1 F1	P2o	P3	P5	P6
R1, thấy đủ 6 camera	51,9	88,2	95,3	78,6	58,3
R1, chỉ thấy CAM_FRONT	0,0	61,6	51,2	60,9	36,6
LoRA không ảnh	21,3	58,4	74,4	53,1	37,1

- Mất ảnh của camera được hỏi, R1 tụt về mức của bản không ảnh (P2o, P5, P6), thậm chí thấp hơn ở P3: ảnh camera trước có thể làm mô hình hiểu sai.
- Bỏ tên camera khỏi prompt thì P1 về 0 vì mô hình không viết được phần CAM_... của thẻ. R1 luôn được train có tên camera, nên điều này cho thấy R1 dựa vào tên camera, chưa chứng minh tên camera là bắt buộc về nguyên tắc.

5. Lựa chọn thiết kế và độ ổn định

Chênh lệch, cùng câu hỏi [95% CI]	P1 F1	P2o	P3	P4	P5	P6
R1 seed 0 − seed 1 (nhiễu giữa hai lần train)	+0,1 [−3,0; +3,2]	−1,5 [−7,2; +3,6]	+1,1 [+0,0; +3,8]	+0,8 [−5,9; +8,4]	+0,5 [−2,3; +3,6]	−1,9 [−6,6; +1,7]
R1 (6 ảnh riêng) − R2 (lưới 3×2)	+0,1 [−3,7; +4,3]	+1,6 [−5,0; +8,1]	**+6,7** [+1,1; +14,0]	+3,5 [−4,8; +12,2]	+3,1 [−0,0; +6,3]	+6,6 [−3,3; +22,9]
40k − 10k mẫu, cùng 2.500 bước	−0,1 [−4,3; +3,5]	+7,3 [−2,2; +17,9]	+4,5 [−2,1; +11,0]	+0,0 [−6,4; +6,4]	+2,3 [−0,9; +5,4]	+3,4 [−5,5; +17,1]
10k: 2.500 − 625 bước (4 so với 1 epoch)	**+5,4** [+1,3; +9,3]	+3,4 [−6,6; +14,9]	+1,1 [−5,1; +6,7]	+0,6 [−9,2; +10,4]	+0,6 [−3,2; +4,2]	+0,2 [−14,8; +17,0]

- **Nhiễu giữa các lần train nhỏ:** ba seed lệch nhau tối đa 2,7 điểm ở mọi chỉ số; cặp seed 0 − seed 1 không có chênh lệch nào có ý nghĩa. Nguồn bất định chính là kích thước tập val (100 câu mỗi loại), không phải seed.
- **6 ảnh riêng so với ảnh lưới:** ngang nhau trừ P3 (+6,7 cho ảnh riêng; R2 đạt 84,3, dưới cả ba seed của R1 là 88,8–91,0). Ảnh lưới không tiết kiệm token (630 so với 588), chậm hơn 10% khi suy luận và 20% khi train. Chọn 6 ảnh riêng.

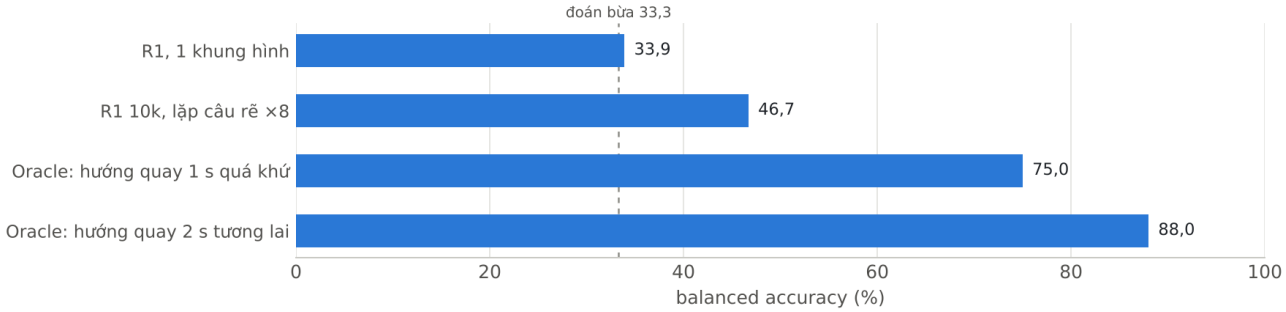
- **Dữ liệu hay số bước?** Từ 10k lên 40k mẫu (1 epoch), P1 tăng 5,3 điểm. Nhưng 10k mẫu train 4 epoch (cùng 2.500 bước) đạt đúng mức đó: mức tăng là do train lâu hơn. Khi cùng số bước, chưa chỉ số nào cho thấy thêm dữ liệu giúp ích; P2o có xu hướng (+7,3) nhưng khoảng tin cậy chứa 0.

6. Câu hỏi về chuyển động và lý do cho giai đoạn 2

P2 hỏi vật thể đang đi thẳng, rẽ trái hay rẽ phải. Trên toàn bộ 1.153 câu val chỉ có 83 câu rẽ (7,2%).

Toàn bộ P2 val	Accuracy	Balanced acc	Recall rẽ (đúng hướng)	Recall rẽ (bất kỳ)	Precision rẽ (bất kỳ)	Tỷ lệ đoán rẽ
B0	92,8	33,3	0,0	0,0	–	0,0
R1	92,3	33,9	1,2	2,4	22,2	0,8
R1 10k, câu rẽ lặp ×8	67,4	46,7	34,9	73,5	15,9	33,2

- Không có oversample, R1 gần như luôn trả lời "đi thẳng" (chỉ 0,8% câu được đoán là rẽ). Lặp câu rẽ ×8 giúp phát hiện "có rẽ" tốt hơn đoán bừa (bắt 73,5% câu rẽ khi chỉ đoán rẽ 33% số câu), nhưng **hướng rẽ ngang tung đồng xu**: đúng hướng ở 29/61 câu bắt được (48%).



Hình 2. Balanced accuracy trên P2. Oracle = luật ngưỡng trên thay đổi góc yaw thật của box nuScenes, ngưỡng chọn trên train, chấm trên val: 1.099 câu có đủ 1 giây quá khứ và tương lai (oracle 1 s), 835 câu có đủ 2 giây (oracle 2 s); hai mô hình chấm trên cả 1.153 câu.

- **Nhãn rẽ của DriveLM dựa một phần vào tương lai:** hướng quay trong 2 giây tới giải thích nhãn tốt hơn 2 giây vừa qua (88,0 so với 74,9, cùng tập câu hỏi). Một phần P2 là câu hỏi dự đoán, mà đầu vào chỉ gồm quá khứ không thể đạt trọn.
- **Nhưng chuyển động quá khứ đã chứa nhiều thông tin:** biết hướng quay thật trong 1 giây vừa qua đã đạt 75%, so với 34% của R1. Mô hình chỉ có camera phải tự ước lượng hướng xe từ 2–3 khung hình, nên 75% là trần trên chứ chưa phải mức chắc đạt được. Dù vậy, khoảng cách lớn này là lý do định lượng để giai đoạn 2 thêm đầu vào nhiều khung hình.
- Nhãn dùng hướng trái/phải của chính vật thể: 93% câu rẽ trên train (có góc quay vượt ngưỡng) quay đúng chiều của nhãn.

7. Lỗi thường gặp của R1

- **P6, nhóm hỗn hợp:** khi đáp án là "vài xe đỗ, vài xe chạy" (7/20 câu trong mẫu kiểm tra tay), R1 luôn trả lời một trạng thái duy nhất và sai cả 7. Đây là lý do chính khiến P6 thấp nhất.
- **P5 bỏ sót hơn là bịa:** trong 20 câu kiểm tra, R1 bỏ sót 15 loại vật thể và chỉ thêm sai 2; thường chỉ kể loại phổ biến (car) và quên loại hiếm.
- **P1, toạ độ còn lệch:** F1 tăng từ 44,6 lên 61,3 khi nới ngưỡng từ 50 lên 200 px. Mỗi token ảnh phủ khoảng 115 × 130 px ảnh gốc, nên ngưỡng 50 px nhỏ hơn nửa ô token.
- **P2o, đỗ hay đang dừng:** phân biệt cần chuyển động, cùng giới hạn như P2.

8. Những gì đã kiểm tra và sửa trong quá trình làm

- **Bộ chấm:** mẫu câu P1–P6 viết theo kế hoạch không khớp mẫu câu thật của v1.1, đã viết lại. "Standing" chưa được hiểu là đứng yên và chưa có nhãn cho câu hỏi về người lái xe, khiến P6 của B0 bị thổi từ 36,9 lên 53,7. "Road sign" chưa được nhận là biển báo (phát hiện khi chấm tay). Đèn giao thông đúng từng bị tính là bịa.
- **Hạ tầng:** hàm tìm run khớp nhầm `r1_10k` với `r1_10k_turnx8`; bảng kết quả từng lấy nhầm run chạy thử 10 câu; config kế thừa bị bỏ qua bước train. Cả ba đã sửa và có test (43 test).

- **Kết luận của chính mình bị dữ liệu bác bỏ:** (1) "loss phẳng thì thêm dữ liệu ít tác dụng", rồi ngược lại "thêm dữ liệu giúp", trong khi thực ra là do số bước; (2) "lặp câu rẽ học được một phần hướng rẽ" (so sai mốc); (3) "độ lệch ±5–9 là nhiễu ngẫu nhiên" (thực ra do đổi dữ liệu train; ba seed chỉ lệch tối đa 2,7); (4) "P2o gần trần 90%". Các sửa đổi này đến từ một vòng phản biện 25 câu và các thí nghiệm kiểm soát chạy sau đó.

9. Giới hạn

- 100 câu val mỗi loại: khoảng tin cậy rộng từ khoảng ±4 điểm (P5) đến ±20 điểm (P6). Khác biệt nhỏ chỉ được coi là có thật khi bootstrap ghép cặp cho thấy.
- Ba seed chỉ có cho R1; R2 và các bản 10k mỗi bản một lần chạy.
- Tập val tách theo scene nhưng chung bốn khu vực của nuScenes, nên đo trong phân phối, chưa đo khái quát sang thành phố mới. Qwen3-VL có thể đã thấy ảnh nuScenes khi pretrain; mọi bản so sánh dùng chung backbone nên so sánh nội bộ vẫn công bằng.
- Chấm tay 100 câu do chính người viết bộ chấm thực hiện, chưa có người chấm độc lập. Quy ước: trailer và xe công trình được gộp vào truck.
- Ablation camera dùng lại checkpoint R1, chưa train riêng. Đánh giá là open-loop, không đo chất lượng lái.

10. Giai đoạn 2

- **Nhiều khung hình:** thêm 2–3 khung hình quá khứ cho camera được hỏi, đo trên P2 và P2o; mục tiêu tiến về trần oracle 75%.
- **Nhóm hỗn hợp và vật thể hiếm:** câu P6 nhiều trạng thái và loại vật thể hiếm trong P5 cần dữ liệu cân bằng hơn hoặc loss có trọng số.
- **Từ perception sang lập kế hoạch:** nối đầu ra perception đã kiểm chứng với câu hỏi prediction/planning của DriveLM và dự đoán quỹ đạo, theo hướng end-to-end.
- **Đánh giá:** thêm ngưỡng tương đối theo kích thước box, latency tách prefill/decode, và tập val lớn hơn để thu hẹp khoảng tin cậy.