VLM hiểu cảnh giao thông đa camera trên DriveLM-nuScenes, kiểm chứng bằng box 3D của nuScenes

Báo cáo kỹ thuật giai đoạn 1 (perception) · Tran Thanh Dat · 11/11/2026
Mã nguồn: `drivelm-perception-vlm` · Phần cứng: 1 × RTX 5060 Ti 16 GB, Ryzen 7 7800X3D, 32 GB RAM · Kiểm tra số liệu: `make verify` (239/239 khớp)

Tóm tắt

Báo cáo trình bày giai đoạn 1 của một dự án lái xe end-to-end dựa trên mô hình ngôn ngữ–thị giác (VLM): dạy một VLM nhỏ trả lời các câu hỏi perception về cảnh giao thông từ 6 camera, và kiểm chứng câu trả lời bằng nhãn 3D thật thay vì chỉ so chữ. Fine-tune Qwen3-VL-2B bằng LoRA (17,4 triệu tham số, 0,81%) trên 40.000 câu hỏi của DriveLM-nuScenes v1.1, với 6 ảnh camera riêng có tên, mất khoảng 4,2 giờ trên một GPU 16 GB. Mọi câu trả lời được đối chiếu với box 3D của nuScenes chiếu xuống ảnh. Trên 700 câu val cố định thuộc 91 scene không dùng khi train, mô hình R1 đạt F1 55,0% khi chỉ ra vật thể quan trọng (mô hình gốc: 0%), và 91,0% / 80,9% / 79,7% ở nhận dạng loại vật thể, trạng thái quan sát, và liệt kê vật thể theo vùng. Thí nghiệm kiểm soát với cùng công thức train nhưng không có ảnh cho thấy ảnh đóng góp +19 đến +35 điểm và giảm thẻ bịa từ 19,0% xuống 5,4%. Ablation theo camera xác nhận mô hình dùng ảnh của chính camera được hỏi. Ba seed lệch nhau tối đa 2,7 điểm; mọi so sánh dùng bootstrap ghép cặp theo scene. Giới hạn chính là chuyển động: từ một khung hình, mô hình gần như không nhận ra xe đang rẽ (balanced accuracy 33,9), trong khi oracle dùng hướng quay thật của 1 giây quá khứ đạt 75,0. Đây là lý do định lượng cho đầu vào nhiều khung hình ở giai đoạn 2.

Nội dung

Ký hiệu và thuật ngữ
1. Giới thiệu
2. Bối cảnh và công trình liên quan
3. Dữ liệu và kiểm chứng nhãn
4. Phương pháp
5. Thiết kế đánh giá
6. Kết quả chính
7. Phân tích
8. Câu hỏi về chuyển động
9. Phân tích lỗi
10. Chi phí và khả năng triển khai
11. Tính tái lập và đảm bảo chất lượng
12. Hạn chế
13. Kết luận và hướng tiếp theo
Phụ lục A–D

Ký hiệu và thuật ngữ

Mô hình và thí nghiệm (tên config trong repo đặt trong ngoặc)

Ký hiệu	Ý nghĩa	Vai trò
B0	Baseline 0 (`b0_prior`): không nhìn ảnh, trả lời bằng đáp án phổ biến nhất trong tập train của cùng mẫu câu hỏi (thẻ vật thể thay bằng <obj>); mẫu câu chưa gặp thì lấy đáp án phổ biến của loại câu	Mức điểm đạt được mà không cần nhìn
B1	Baseline 1 (`b1_siglip`): SigLIP2 zero-shot, so vùng cắt 320 × 320 px quanh thẻ trong câu hỏi với các nhãn ứng viên; chỉ trả lời được P2, P2o, P3	Bộ mã hoá ảnh mạnh nhưng không sinh chữ
B2	Baseline 2 (`b2_zeroshot`): Qwen3-VL-2B-Instruct gốc, không fine-tune, nhận đủ 6 ảnh	Mô hình gốc làm được bao nhiêu
B2 few-shot	B2 được xem thêm 2 câu trả lời mẫu cùng loại câu hỏi, chỉ dạng chữ (`b2_fewshot`)	Tách phần "học định dạng" khỏi phần "học nhìn"
T	Text-only (`r1_textonly`): LoRA giống hệt R1 (40.000 mẫu, 2.500 bước) nhưng bỏ hết ảnh	Tách phần nhờ ảnh khỏi phần nhờ câu hỏi
R1	Mô hình chính (`r1_6cam`): Qwen3-VL-2B + LoRA, 6 ảnh camera riêng có tên, 40.000 mẫu, 1 epoch, tắt ngẫu nhiên 15% camera không được hỏi	Kết quả chính của giai đoạn 1
R1 seed 0 / 1 / 2	R1 train lại với seed 0, 1, 2 (`r1_6cam`, `r1_seed1`, `r1_seed2`); "R1" không ghi seed nghĩa là seed 0	Đo nhiễu giữa các lần train
R2	R1 nhưng ghép 6 ảnh thành một ảnh lưới 3 × 2, cùng độ phân giải mỗi ô (`r2_grid`)	So cách đưa nhiều camera vào
D1	R1 với 10.000 mẫu × 1 epoch = 625 bước (`r1_10k`)	Ít dữ liệu, ít bước
D4	R1 với 10.000 mẫu × 4 epoch = 2.500 bước, bằng số bước của R1 (`r1_10k_4ep`)	Tách tác động của dữ liệu khỏi số bước
D×8	D1 nhưng câu rẽ của P2 được lặp 8 lần trước khi lấy mẫu (`r1_10k_turnx8`)	Thử khắc phục mất cân bằng câu rẽ
A-front	Ablation: checkpoint R1, khi đánh giá chỉ đưa ảnh CAM_FRONT (`abl_front_only`)	Mô hình có dùng ảnh của đúng camera không
A-name	Ablation: checkpoint R1, khi đánh giá bỏ tên camera khỏi prompt (`abl_no_camname`)	Mô hình có dựa vào tên camera không
Oracle	Luật ngưỡng trên thay đổi góc quay thật của box nuScenes trong 1–3 giây quá khứ hoặc tương lai; không phải mô hình học máy	Trần trên cho câu hỏi rẽ (P2)
p2full_*	Các mô hình trên chấm lại P2 trên toàn bộ 1.153 câu val thay vì 100	Đủ câu rẽ (83) để đo

Loại câu hỏi

Ký hiệu	Câu hỏi	Câu trả lời mong đợi
P1	Vật thể quan trọng trong cảnh	Danh sách thẻ <c, CAMERA, x, y>
P2	Trạng thái di chuyển của một vật thể (moving status)	Đi thẳng / rẽ trái / rẽ phải
P2o	Trạng thái quan sát của một vật thể (observed status; o = observed)	Đang chạy / đứng yên
P3	Mô tả hình ảnh của một vật thể	Câu mô tả; chấm theo loại vật thể suy ra (car, truck, pedestrian, ...)
P4	Có loại vật thể X với trạng thái Y ở vùng Z không?	Có / không
P5	Những vật thể nào ở vùng Z?	Danh sách loại vật thể
P6	Trạng thái của các vật thể loại X ở vùng Z	Đang chạy / đỗ / đứng / có hoặc không có người lái, có thể hỗn hợp
Thẻ <c, CAM, x, y>	Cách DriveLM chỉ một vật thể: mã vật thể, tên camera, toạ độ tâm (pixel) trên ảnh gốc 1600 × 900 của camera đó	
Vùng	front, front left, front right, back, back left, back right; mỗi vùng tương ứng một camera (front left → CAM_FRONT_LEFT)	

Chỉ số và thuật ngữ

Ký hiệu	Ý nghĩa
τ (tau)	Ngưỡng khoảng cách (pixel, ảnh gốc) để một thẻ dự đoán được tính là trùng thẻ đáp án; dùng τ = 50, 100, 200 px, chính là 100
Precision / Recall / F1	Tỷ lệ thẻ (hoặc loại vật thể) dự đoán là đúng / tỷ lệ đáp án được tìm ra / trung bình điều hoà của hai tỷ lệ
Ghép Hungarian	Ghép một–một giữa thẻ dự đoán và thẻ đáp án sao cho tổng khoảng cách nhỏ nhất, trước khi áp ngưỡng τ
Grounding	Tỷ lệ thẻ dự đoán nằm trong một box nuScenes bất kỳ (mô hình chỉ vào chỗ có vật thể thật)
Bịa (hallucination)	Tỷ lệ thẻ dự đoán không nằm trong box nào, cách box gần nhất hơn 100 px, và không trùng thẻ đáp án nào
Accuracy	Tỷ lệ câu trả lời đúng
Macro-F1	Trung bình F1 của từng nhãn, mỗi nhãn nặng như nhau; không bị nhãn phổ biến lấn át
Balanced accuracy	Trung bình recall của từng nhãn; đoán bừa với 3 nhãn cho 33,3, với 2 nhãn cho 50
Recall / precision câu rẽ	Tỷ lệ câu rẽ thật được đoán là rẽ / tỷ lệ câu bị đoán là rẽ mà đúng là rẽ; "đúng hướng" đòi đúng cả trái/phải, "bất kỳ" thì không
Không đọc được	Tỷ lệ câu trả lời mà bộ chấm không rút ra được nhãn (parse-fail)
Collapse	Mô hình trả lời cùng một đáp án cho mọi câu của một loại
95% CI [a; b]	Khoảng tin cậy 95%: tính bằng bootstrap 1.000 lần, mỗi lần rút lại cả scene có hoàn lại
Bootstrap ghép cặp	So hai mô hình trên cùng các câu hỏi: mỗi lần rút lại scene, tính hiệu A − B; chênh lệch có thật khi khoảng tin cậy của hiệu không chứa 0
Tập "sạch"	Các câu mà nhãn DriveLM không mâu thuẫn nhãn nuScenes (bỏ các câu đánh dấu nusc_disagree)
Scene / keyframe	Scene: một đoạn lái khoảng 20 giây của nuScenes; keyframe: thời điểm có nhãn 3D (2 lần mỗi giây), mỗi keyframe có 6 ảnh camera
LoRA, r, α	Fine-tune bằng ma trận hạng thấp gắn vào mô hình gốc (đóng băng); r là hạng, α là hệ số tỷ lệ
Mẫu, epoch, bước	Mẫu: một cặp câu hỏi–trả lời. Epoch: một lượt qua toàn bộ mẫu train. Bước: một lần cập nhật trọng số (16 mẫu)
10k / 40k	10.000 / 40.000 mẫu train
Seed	Số khởi tạo bộ sinh số ngẫu nhiên (chọn mẫu, thứ tự, camera bị tắt, khởi tạo LoRA)
Token ảnh	Số đơn vị đầu vào mà ảnh chiếm trong mô hình; mỗi camera 98 token, mỗi token phủ khoảng 115 × 130 px ảnh gốc
Latency p50	Thời gian trả lời một câu hỏi, giá trị trung vị (50% câu nhanh hơn)
Open-loop	Đánh giá trên dữ liệu đã ghi sẵn, đầu ra của mô hình không tác động lại cảnh

1. Giới thiệu

Các hệ lái xe end-to-end dựa trên VLM hứa hẹn kết hợp hiểu cảnh, lập luận và hành động trong một mô hình. Nhưng trước khi tin vào quyết định lái của một VLM, cần biết nó có *nhìn đúng* hay không: vật thể quan trọng ở đâu, là gì, đang làm gì. Phần lớn đánh giá câu hỏi–trả lời về lái xe chấm bằng độ giống chữ (BLEU, ROUGE, CIDEr) hoặc bằng một LLM khác. Cả hai cách không trả lời được câu hỏi "mô hình có nhìn đúng không".

Giai đoạn 1 của dự án tập trung vào perception, với ba câu hỏi:

- **Q1.** Một VLM 2B tham số, fine-tune trên một GPU phổ thông, chỉ ra được bao nhiêu vật thể quan trọng, và bịa ra bao nhiêu (chỉ vào chỗ không có vật thể nào)?
- **Q2.** Bao nhiêu phần điểm số thật sự đến từ ảnh, và bao nhiêu chỉ là học thuộc cách đặt câu hỏi? Mô hình có dùng ảnh của đúng camera không?
- **Q3.** Những gì không suy ra được từ một khung hình (chuyển động), và trần trên nếu có thêm thông tin chuyển động là bao nhiêu?

Đóng góp.

- Một pipeline kiểm chứng câu trả lời của DriveLM bằng box 3D của nuScenes: nối 99,1% thẻ vật thể với box, đo mức khớp của nhãn DriveLM (89,7–94,3%), và chấm mọi câu trả lời theo nghĩa vật lý thay vì theo chữ.
- Một mô hình R1 (Qwen3-VL-2B + LoRA, 6 camera) đạt P1 F1 55,0% với 5,4% thẻ bịa, train trong khoảng 4,2 giờ trên GPU 16 GB.
- Một bộ thí nghiệm kiểm soát tách được phần nhờ ảnh và phần nhờ câu hỏi (LoRA không ảnh), phần nhờ dữ liệu và phần nhờ số bước train, và nhiễu giữa các seed; mọi so sánh kèm khoảng tin cậy ghép cặp theo scene.
- Một phân tích oracle cho thấy nhãn "rẽ" của DriveLM phụ thuộc một phần vào tương lai, và lượng thông tin có trong chuyển động quá khứ.
- Toàn bộ kết quả tái lập được: 43 test, kiểm tra tính toàn vẹn của mọi run, và một lệnh đối chiếu 239 con số của báo cáo với kết quả tính lại.

2. Bối cảnh và công trình liên quan

DriveLM. DriveLM [1] tổ chức hiểu cảnh lái xe thành chuỗi câu hỏi perception → prediction → planning trên ảnh của nuScenes [2]. Các câu hỏi perception tham chiếu vật thể bằng thẻ <c, CAMERA, x, y> (toạ độ tâm trên ảnh 1600 × 900), nên có thể đối chiếu với nhãn 3D của nuScenes. Đánh giá chính thức dùng độ chính xác, các chỉ số ngôn ngữ và điểm do GPT chấm; báo cáo này thay bằng các chỉ số kiểm chứng được (mục 5).

VLM và VLA cho lái xe. Nhiều công trình gần đây dựng mô hình vision-language-action trên VLM mã nguồn mở để vừa trả lời câu hỏi vừa sinh quỹ đạo, ví dụ OpenDriveVLA [4] và AutoVLA [7], đánh giá trên nuScenes và NAVSIM. Giai đoạn 1 của dự án này dừng ở perception và cố ý dùng một mô hình nhỏ (2B) trên phần cứng phổ thông, để đo kỹ những gì mô hình nhìn được trước khi thêm hành động.

Thận trọng với đánh giá open-loop. Li và cs. [3] chỉ ra rằng trên nuScenes, các mô hình end-to-end có dùng trạng thái xe thường dựa chủ yếu vào trạng thái đó để lập quỹ đạo, và một baseline chỉ dùng trạng thái xe đã đạt kết quả cạnh tranh. Bài học áp dụng cho cả perception: cần baseline không dùng ảnh để biết ảnh thật sự đóng góp gì. Báo cáo này dùng hai baseline như vậy: B0 (đáp án phổ biến theo mẫu câu) và LoRA không ảnh.

3. Dữ liệu và kiểm chứng nhãn

3.1 Nguồn dữ liệu và cách chia

Dữ liệu gồm file câu hỏi DriveLM-nuScenes v1.1 (Hugging Face OpenDriveLab/DriveLM), ảnh 6 camera của các keyframe tương ứng, và metadata nuScenes v1.0-trainval (chỉ các bảng JSON, không có dữ liệu cảm biến thô). Chỉ dùng nhóm câu hỏi perception. Tập dữ liệu được chia theo scene (90% / 10%, seed 0) để không có scene nào xuất hiện ở cả train và val.

Bảng 1. Thống kê dữ liệu sau khi chia theo scene (4.072 keyframe).

	Train	Val	Tổng
Scene	605	91	696
Câu hỏi perception	141.808	20.672	162.480
Boston / Singapore (câu hỏi)	89.405 / 52.403	12.385 / 8.287	101.790 / 60.690
Ban ngày / ban đêm / mưa (câu hỏi)	99.927 / 13.441 / 28.440	15.474 / 2.149 / 3.049	

3.2 Bảy loại câu hỏi được chấm

30 mẫu câu perception của v1.1 được gom thành 7 loại có thể chấm tự động. Nhóm "other" (mô tả cảnh, vị trí tương đối, làn đường, phân loại đèn/biển báo) vẫn được dùng khi train nhưng không chấm vì câu trả lời tự do.

Bảng 2. Các loại câu hỏi và số câu. Vùng (front left, back, ...) tương ứng một camera.

Loại	Mẫu câu hỏi	Train	Val	Chấm bằng
P1	What are the important objects in the current scene?	3.543	529	Thẻ <c,CAM,x,y>: F1 sau ghép Hungarian
P2	What is the moving status of object <tag>?	7.624	1.153	Đi thẳng / rẽ trái / rẽ phải
P2o	What is the observed status of object <tag>?	13.439	1.944	Moving / stationary, macro-F1
P3	What is the visual description of <tag>?	15.087	2.195	Loại vật thể, accuracy
P4	Are there {parked, moving, ...} {cars, ...} to the {region}?	40.343	5.874	Có / không, balanced accuracy
P5	What are objects to the {region} of the ego car?	17.450	2.535	F1 trên tập loại vật thể
P6	What is the status of the {objects} to the {region}?	33.086	4.742	Trạng thái (kể cả có/không người lái), macro-F1
other	Mô tả cảnh, vị trí, làn đường, đèn/biển báo	11.236	1.700	Chỉ dùng khi train

Tập val cố định. Lấy ngẫu nhiên có phân tầng 100 câu cho mỗi loại từ P1 đến P6 (700 câu), dùng chung cho mọi mô hình. Vì câu rẽ hiếm (7,2% câu P2), P2 còn được chấm trên toàn bộ 1.153 câu val.

3.3 Kiểm chứng nhãn DriveLM bằng nuScenes

Box 3D của nuScenes ở mỗi keyframe được chiếu xuống 6 ảnh (cài đặt bằng numpy, không dùng devkit). Mỗi thẻ của DriveLM được nối với một box: ưu tiên box có IoU lớn nhất với box 2D mà DriveLM cung cấp, nếu không thì box chứa điểm thẻ. Từ đó so được nhãn của DriveLM với thuộc tính của nuScenes.

Bảng 3. Kiểm chứng nhãn trên toàn bộ dữ liệu (n = 15.231 thẻ có trạng thái).

Kiểm tra	Kết quả	Ghi chú
Thẻ nối được với box nuScenes	99,1%	Vehicle 99,3 · Pedestrian 99,8 · Cycle 99,7 · Others 86,9. Đèn và biển báo (1.875 thẻ) không có box trong nuScenes nên không nối
Trạng thái DriveLM khớp nuScenes	89,7%	DriveLM gọi xe dừng tạm (vehicle.stopped) là "Stationary"; nếu tính stopped là đang chạy, độ khớp giảm còn 79,8%
Loại vật thể khớp	94,3%	Sau khi theo quy ước nuScenes: van là car, người đi xe máy/xe đạp là cycle. Còn lại là khác biệt thật (SUV hay truck)
P4 có/không khớp box	93,7%	Khi "parked" tính cả xe dừng tạm (theo nghĩa đen: 90,3%). DriveLM đếm cả vật thể khó thấy

Khoảng 1/10 nhãn DriveLM mâu thuẫn với nhãn 3D. Các câu này được đánh dấu `nusc_disagree` và chấm riêng (Bảng 17, Phụ lục B). Mô hình vẫn được chấm theo nhãn DriveLM, vì đó là nhãn nó học.

4. Phương pháp

4.1 Mô hình và định dạng đầu vào

Mô hình nền là Qwen3-VL-2B-Instruct. Mỗi câu hỏi được đưa vào dạng hội thoại: một câu hệ thống mô tả quy ước thẻ (toạ độ tâm trên ảnh gốc 1600 × 900 của camera), sau đó 6 ảnh camera theo thứ tự cố định, mỗi ảnh có tên camera đi kèm (CAM_FRONT_LEFT, CAM_FRONT, ...), rồi câu hỏi. Mỗi ảnh được thu về ngân sách tối đa 448 × 252 px; sau khi làm tròn theo lưới patch, mỗi camera chiếm 98 token, tổng 588 token ảnh. Mỗi token phủ khoảng 115 × 130 px ảnh gốc.

Biến thể R2 (ảnh lưới): ghép 6 ảnh thành một lưới 3 × 2 với cùng độ phân giải mỗi ô, kèm một câu mô tả ô nào là camera nào; mô hình vẫn trả lời toạ độ theo ảnh camera gốc. **Biến thể không ảnh:** bỏ hết ảnh, giữ nguyên mọi thứ khác.

4.2 Fine-tune

Bảng 4. Cấu hình train của R1. Các biến thể chỉ đổi đúng một yếu tố (Phụ lục A).

Thành phần	Giá trị
LoRA	r = 16, α = 32, dropout 0,05; trên q, k, v, o và MLP (gate, up, down) của phần ngôn ngữ; encoder ảnh đóng băng
Tham số train	17.432.576 (0,81% của 2,14 tỷ)
Tối ưu	lr 2 × 10^{-4}, cosine, warmup 3% (75 bước); batch 1 × tích luỹ gradient 16; bf16; gradient checkpointing
Dữ liệu train	40.000 câu, lấy mẫu cân bằng theo loại câu: P1 3.543 (toàn bộ), mỗi loại khác 5.208; 1 epoch = 2.500 bước
Loss	Chỉ trên phần câu trả lời (che phần hệ thống, ảnh và câu hỏi); kiểm tra tự động trước khi train
Tắt camera ngẫu nhiên	Mỗi camera không được câu hỏi nhắc tới bị bỏ với xác suất 0,15
Sinh câu trả lời	Greedy, tối đa 256 token
Thời gian / bộ nhớ	Khoảng 6,0 giây mỗi bước, 4,2 giờ mỗi run; 4,2 GB VRAM khi suy luận

4.3 Các baseline và thí nghiệm kiểm soát

Bảng 5. Baseline và thí nghiệm kiểm soát.

ID	Mô tả	Mục đích
B0	Đáp án phổ biến nhất trong train cho từng mẫu câu (thẻ thay bằng <obj>); mẫu câu lạ thì lấy đáp án phổ biến theo loại	Mức điểm đạt được không cần nhìn
B1	SigLIP2 zero-shot trên vùng cắt 320 × 320 px quanh thẻ trong câu hỏi, chọn nhãn có độ tương đồng cao nhất	Bộ mã hoá ảnh mạnh, không sinh chữ
B2	Qwen3-VL-2B zero-shot; và bản few-shot với 2 câu trả lời mẫu cùng loại (chỉ chữ)	Mô hình gốc làm được bao nhiêu; phần nào chỉ là định dạng
T	LoRA y hệt R1 nhưng không có ảnh	Tách phần nhờ ảnh khỏi phần nhờ câu hỏi
R1 s1, s2	R1 với seed 1 và 2	Nhiễu giữa các lần train
R2	R1 với một ảnh lưới 3 × 2	Cách đưa nhiều camera vào
D1, D4, D×8	10.000 mẫu × 1 epoch; × 4 epoch (2.500 bước như R1); câu rẽ lặp × 8	Dữ liệu hay số bước; mất cân bằng câu rẽ
A-front, A-name	Checkpoint R1 khi chỉ đưa CAM_FRONT; khi bỏ tên camera	Mô hình có dùng ảnh của đúng camera

5. Thiết kế đánh giá

5.1 Chỉ số

- **P1 (vật thể quan trọng).** Ghép thẻ dự đoán với thẻ đáp án trong cùng camera bằng thuật toán Hungarian; một cặp đúng nếu khoảng cách ≤ τ (50, 100, 200 px trên ảnh gốc). Báo cáo precision, recall, F1 (chính: τ = 100). **Grounding**: tỷ lệ thẻ dự đoán nằm trong một box nuScenes. **Thẻ bịa**: thẻ không nằm trong box nào, cách box gần nhất hơn 100 px, và không khớp thẻ đáp án nào (điều kiện cuối để đèn/biển báo đúng không bị tính bịa).
- **P2, P2o, P6**: câu trả lời được chuẩn hoá về nhãn trạng thái (moving, stopped, rẽ trái/phải, có/không người lái); macro-F1. Với P2 toàn val, báo cáo thêm balanced accuracy, recall và precision câu rẽ (đúng hướng và bất kỳ hướng), và tỷ lệ câu bị đoán là rẽ.
- **P3**: loại vật thể suy từ câu mô tả (theo quy ước nuScenes) so với nhãn DriveLM; accuracy. **P4**: có/không, balanced accuracy. **P5**: F1 vi mô trên tập loại vật thể được nhắc tới.
- **Độ bền**: tỷ lệ không đọc được câu trả lời; cảnh báo khi mô hình chỉ trả lời một đáp án cho mọi câu (collapse).

5.2 Độ bất định

Các câu hỏi trong cùng một scene tương quan với nhau (cùng thời tiết, cùng vật thể). Vì vậy khoảng tin cậy 95% được tính bằng bootstrap 1.000 lần, mỗi lần rút lại *cả scene* có hoàn lại (seed 0). Khi so hai mô hình, dùng bootstrap ghép cặp: hai mô hình được chấm trên cùng các scene rút ra mỗi lần, nên nhiễu do tập val phần lớn triệt tiêu. Một chênh lệch được coi là có thật khi khoảng tin cậy của nó không chứa 0. Nhiễu giữa các lần train được đo riêng bằng 3 seed.

5.3 Kiểm tra bộ chấm

Bộ chấm dựa trên từ khoá được kiểm tra tay trên 100 câu trả lời của R1 (20 câu mỗi loại P2o, P3, P4, P5, P6): bộ chấm hiểu đúng 99/100. Lỗi duy nhất là "Road sign" chưa được nhận là biển báo, đã sửa và chấm lại. Người kiểm tra là người viết bộ chấm, chưa phải người chấm độc lập.

6. Kết quả chính

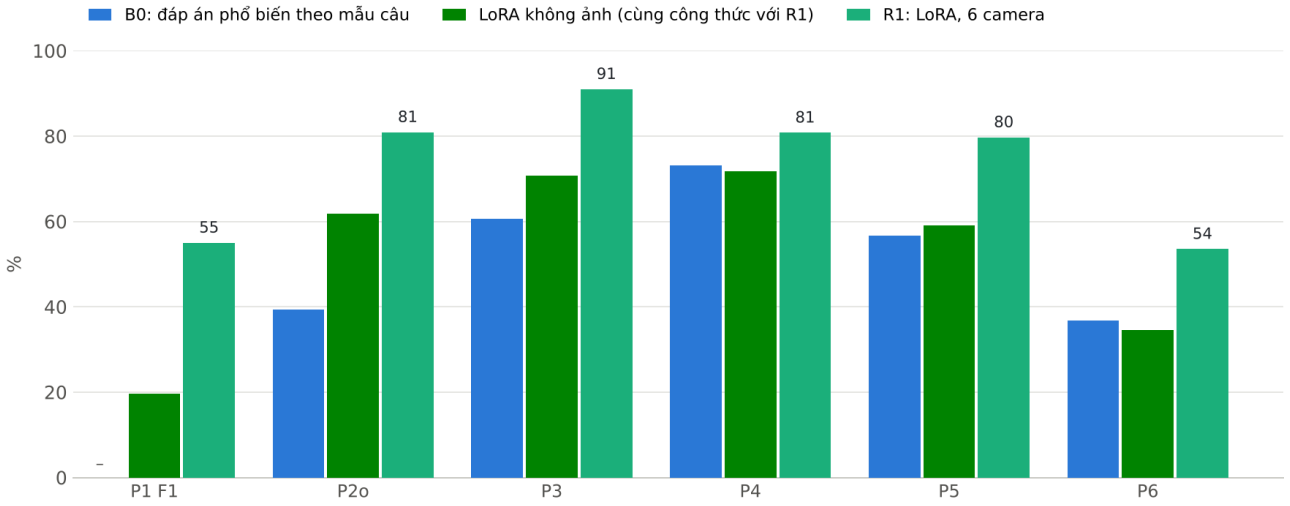
Bảng 6. Kết quả trên 700 câu val cố định (đơn vị %). P2o, P6: macro-F1; P3: accuracy; P4: balanced accuracy; P5: F1. Latency đo trên RTX 5060 Ti. * B1 chỉ chạy encoder trên một vùng cắt, không sinh chữ.

Mô hình	P1 F1	Bịa	P2o	P3	P4	P5	P6	Không đọc được	Latency p50
B0: đáp án phổ biến	–	–	39,4	60,7	73,1	56,7	36,9	0	–
B1: SigLIP2 zero-shot	–	–	37,8	73,0	–	–	–	0	0,03 s*
B2: Qwen3-VL-2B zero-shot	0,0	–	32,7	68,5	59,3	21,8	8,1	16,7%	0,46 s
B2 few-shot (2 ví dụ)	3,3	54,6%	35,9	60,7	63,0	64,0	13,5	4,6%	0,21 s
T: LoRA không ảnh	19,7	19,0%	61,8	70,8	71,7	59,2	34,6	0,1%	0,10 s
R1: LoRA, 6 ảnh (seed 0)	**55,0**	5,4%	**80,9**	**91,0**	80,8	**79,7**	**53,6**	0,1%	0,22 s
R1 seed 1	54,9	4,8%	82,4	89,9	80,0	79,3	55,4	0,1%	0,23 s
R1 seed 2	54,2	6,8%	82,2	88,8	81,5	77,1	52,7	0,1%	0,23 s
R2: LoRA, ảnh lưới	54,9	5,7%	79,3	84,3	77,3	76,6	47,0	0,3%	0,24 s
D1: 10k × 1 epoch	49,7	4,3%	70,2	85,4	80,3	76,8	49,9	0,3%	0,22 s
D4: 10k × 4 epoch	55,1	5,4%	73,6	86,5	80,8	77,4	50,1	0,4%	0,23 s
D×8: 10k, câu rẽ × 8	47,9	4,8%	79,0	85,4	84,3	76,5	42,3	0,1%	0,22 s

Khoảng tin cậy 95% theo scene của từng ô rộng từ khoảng ±4 điểm (P5) đến ±20 điểm (P6), ví dụ R1: P1 [50,0; 59,5], P3 [85,2; 96,6], P5 [75,4; 83,3], P6 [35,6; 76,5] (đầy đủ ở Phụ lục B). Vì vậy mọi so sánh ở mục 7 dùng bootstrap ghép cặp. Bảng 7 cho P1 ở các ngưỡng khác nhau.

Bảng 7. P1 theo ngưỡng khoảng cách. F1 tăng mạnh khi nới ngưỡng: R1 tìm đúng vật thể nhưng toạ độ còn lệch (mục 9).

Mô hình	τ = 50 px	τ = 100 px	τ = 200 px	Grounding	Bịa
T: LoRA không ảnh	10,6	19,7	32,9	54,5%	19,0%
B2 few-shot	1,1	3,3	7,0	20,7%	54,6%
R1 (seed 0 / 1 / 2)	44,6 / 44,4 / 44,3	55,0 / 54,9 / 54,2	61,3 / 59,7 / 60,4	89,7 / 89,2 / 89,0%	5,4 / 4,8 / 6,8%
R2: ảnh lưới	42,0	54,9	61,9	87,8%	5,7%



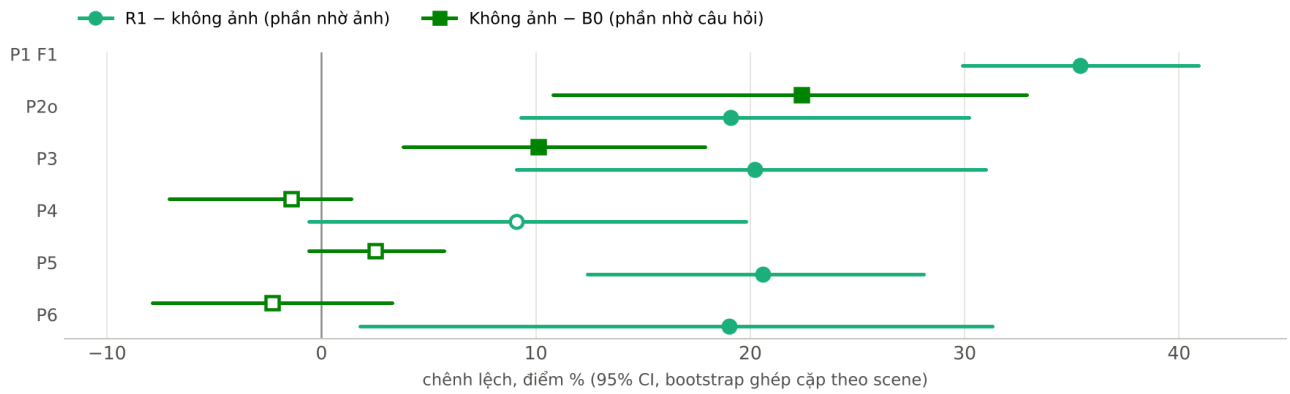
Hình 1. B0, LoRA không ảnh và R1 theo loại câu. Khoảng cách xanh lá → xanh ngọc là phần nhờ ảnh; xanh dương → xanh lá là phần học được từ câu hỏi.

7. Phân tích

7.1 Phần nào của điểm số đến từ ảnh?

Bảng 8. Bootstrap ghép cặp theo scene (1.000 lần). In đậm: khoảng tin cậy không chứa 0.

Chênh lệch [95% CI]	P1 F1	Bịa	P2o	P3	P4	P5	P6
R1 − không ảnh	**+35,4** [+29,9; +40,9]	**−13,6** [−20,5; −7,5]	**+19,1** [+9,3; +30,2]	**+20,2** [+9,1; +31,0]	+9,1 [−0,6; +19,8]	**+20,6** [+12,4; +28,1]	**+19,0** [+1,8; +31,3]
Không ảnh − B0	–	–	**+22,4** [+10,8; +32,9]	**+10,1** [+3,8; +17,9]	−1,4 [−7,1; +1,4]	+2,5 [−0,6; +5,7]	−2,3 [−7,9; +3,3]
R1 − B0	–	–	**+41,5** [+32,8; +49,4]	**+30,3** [+18,8; +42,2]	+7,7 [−3,8; +20,0]	**+23,0** [+14,4; +30,9]	+16,7 [−2,6; +31,1]



Hình 2. Phần nhờ ảnh và phần nhờ câu hỏi. Điểm tô đặc: khoảng tin cậy không chứa 0.

- **Ảnh giúp có thật ở 6/7 chỉ số.** Riêng P4 chưa chứng minh được: câu có/không theo vùng đã đoán khá tốt từ mẫu câu (B0 73,1).
- **Chỉ fine-tune trên chữ đã tăng P2o 22 điểm.** Câu hỏi về trạng thái chứa gợi ý (loại vật thể, vị trí) mà B0, vốn chỉ nhớ một đáp án cho mỗi mẫu câu, không tận dụng được. Khoảng một nửa mức tăng P2o của R1 so với B0 đến từ đây. Nếu chỉ so với B0 sẽ đánh giá quá cao vai trò của ảnh.
- **Bản không ảnh đạt P1 F1 19,7** nhờ đoán các vị trí hay gặp (xe ngay phía trước), nhưng 19% thẻ là bịa và chỉ 54,5% thẻ nằm trong box nào đó.

7.2 Mô hình có dùng ảnh của đúng camera không?

Bảng 9. Điểm trên các câu hỏi về camera không phải CAM_FRONT (ví dụ với P4: 73 câu, so với 27 câu về CAM_FRONT). Đầy đủ ở Phụ lục C.

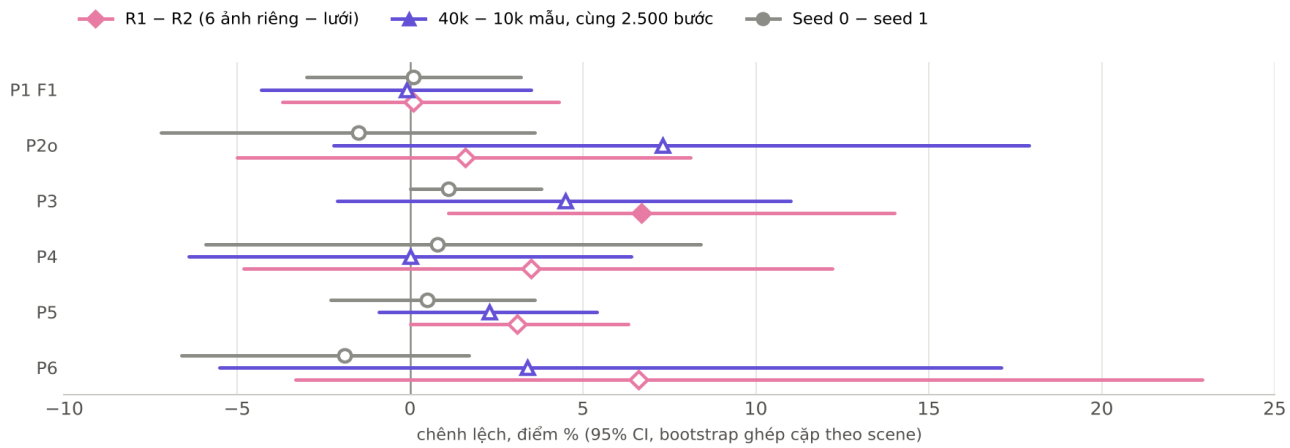
Câu hỏi về 5 camera khác CAM_FRONT	P1 F1	P2o	P3	P5	P6
R1, thấy đủ 6 camera	51,9	88,2	95,3	78,6	58,3
R1, chỉ thấy CAM_FRONT	0,0	61,6	51,2	60,9	36,6
T: LoRA không ảnh	21,3	58,4	74,4	53,1	37,1
B0	–	38,4	62,8	52,0	38,6

- Mất ảnh của camera được hỏi, R1 tụt 18–44 điểm, về gần mức của bản không ảnh (P2o, P5, P6). Ở P3 còn thấp hơn bản không ảnh (51,2 so với 74,4): có thể ảnh camera trước làm mô hình mô tả nhầm sang vật thể khác. Trên câu hỏi về CAM_FRONT, điểm gần như giữ nguyên (P3 87,0; P4 95,8).
- Tổng thể, ablation chỉ CAM_FRONT giảm P1 20,0 điểm, P3 21,4, P2o 16,1, P5 12,9 so với R1 (đều có ý nghĩa, ghép cặp).
- Bỏ tên camera khỏi prompt thì P1 về 0 vì mô hình không viết được phần CAM_... của thẻ (15% câu trả lời không đọc được). Vì R1 luôn được train có tên camera, điều này cho thấy R1 dựa vào tên camera, chưa chứng minh tên camera là bắt buộc về nguyên tắc.

7.3 Lựa chọn thiết kế: ảnh riêng hay ảnh lưới, dữ liệu hay số bước, và seed

Bảng 10. So sánh thiết kế, bootstrap ghép cặp theo scene.

Chênh lệch [95% CI]	P1 F1	P2o	P3	P4	P5	P6
R1 − R2 (6 ảnh riêng − lưới)	+0,1 [−3,7; +4,3]	+1,6 [−5,0; +8,1]	**+6,7** [+1,1; +14,0]	+3,5 [−4,8; +12,2]	+3,1 [−0,0; +6,3]	+6,6 [−3,3; +22,9]
40k − 10k mẫu, cùng 2.500 bước	−0,1 [−4,3; +3,5]	+7,3 [−2,2; +17,9]	+4,5 [−2,1; +11,0]	+0,0 [−6,4; +6,4]	+2,3 [−0,9; +5,4]	+3,4 [−5,5; +17,1]
10k: 4 − 1 epoch (2.500 − 625 bước)	**+5,4** [+1,3; +9,3]	+3,4 [−6,6; +14,9]	+1,1 [−5,1; +6,7]	+0,6 [−9,2; +10,4]	+0,6 [−3,2; +4,2]	+0,2 [−14,8; +17,0]
Seed 0 − seed 1	+0,1 [−3,0; +3,2]	−1,5 [−7,2; +3,6]	+1,1 [+0,0; +3,8]	+0,8 [−5,9; +8,4]	+0,5 [−2,3; +3,6]	−1,9 [−6,6; +1,7]



Hình 3. Các so sánh thiết kế. Điểm tô đặc: khoảng tin cậy không chứa 0. Chỉ R1 − R2 ở P3 và 4 − 1 epoch ở P1 (Bảng 10) là có ý nghĩa.

- **Ảnh riêng so với ảnh lưới.** Ngang nhau trừ P3 (+6,7 cho ảnh riêng; R2 đạt 84,3, dưới cả ba seed của R1 là 88,8–91,0). Ảnh lưới không tiết kiệm token (630 so với 588), chậm hơn 10% khi suy luận (0,244 so với 0,222 s) và 20% khi train (7,2 so với 6,0 s mỗi bước). Kết luận: dùng 6 ảnh riêng có tên camera.
- **Dữ liệu hay số bước.** Từ 10k lên 40k mẫu (cùng 1 epoch), P1 tăng 5,3 điểm. Nhưng 10k mẫu × 4 epoch (cùng 2.500 bước) đạt đúng mức đó (55,1): mức tăng là do train lâu hơn. Khi số bước bằng nhau, chưa chỉ số nào cho thấy thêm dữ liệu giúp ích; P2o có xu hướng (+7,3) nhưng khoảng tin cậy chứa 0.
- **Seed.** Ba seed lệch nhau tối đa 2,7 điểm (P6 52,7–55,4; P5 77,1–79,7; P3 88,8–91,0; P1 54,2–55,0). Cặp seed 0 − seed 1 không có chênh lệch nào có ý nghĩa. Nguồn bất định chính là kích thước tập val, không phải seed.

7.4 Fine-tune học định vị hay chỉ học định dạng?

Mô hình gốc zero-shot không viết được thẻ đúng định dạng (P1 = 0; 16,7% câu trả lời không đọc được). Khi được xem 2 câu trả lời mẫu, nó học được cách trả lời: tỷ lệ không đọc được giảm còn 4,6% và P5 tăng từ 21,8 lên 64,0. Nhưng P1 chỉ đạt 3,3 với 54,6% thẻ bịa và 20,7% thẻ nằm trong box. Như vậy biết viết thẻ không có nghĩa là chỉ đúng vật thể. Trong 55 điểm P1 của R1, khoảng 20 điểm đạt được cả khi không có ảnh (đoán vị trí hay gặp) và +35 điểm đến từ việc nhìn ảnh.

7.5 Thành phố, thời tiết và nhãn mâu thuẫn

Bảng 11. P1 theo nhóm (số câu P1 trong ngoặc).

P1 F1 / bịa	Boston (59)	Singapore (41)	Ban ngày (69)	Ban đêm (11)	Mưa (20)
R1 seed 0	52,6 / 4,2%	59,3 / 7,5%	53,5 / 4,6%	71,4 / 4,4%	50,6 / 8,5%
R1 seed 1	52,7 / 5,6%	58,9 / 3,4%	52,8 / 3,8%	70,2 / 0,0%	53,4 / 10,2%
R1 seed 2	52,2 / 6,4%	57,7 / 7,4%	52,9 / 7,2%	68,6 / 0,0%	50,3 / 9,2%
T: LoRA không ảnh	19,5 / 8,5%	19,8 / 34,1%	19,1 / 22,5%	29,3 / 9,1%	15,6 / 12,5%

Singapore cao hơn Boston khoảng 6 điểm ở cả ba seed. Ban đêm có điểm cao nhất nhưng chỉ có 11 câu, nên không nên kết luận. Mưa có tỷ lệ thẻ bịa cao nhất (8,5–10,2%), phù hợp với ảnh mờ và phản chiếu. Trên tập "sạch" (bỏ các câu có nhãn DriveLM mâu thuẫn nuScenes), thứ hạng các mô hình không đổi (Bảng 17, Phụ lục B).

8. Câu hỏi về chuyển động

P2 hỏi vật thể đang đi thẳng, rẽ trái hay rẽ phải. Trên toàn bộ 1.153 câu val chỉ có 83 câu rẽ (7,2%); trong 5.208 câu P2 dùng để train R1 chỉ có 419 câu rẽ.

Bảng 12. P2 trên toàn bộ val (1.153 câu, 83 câu rẽ).

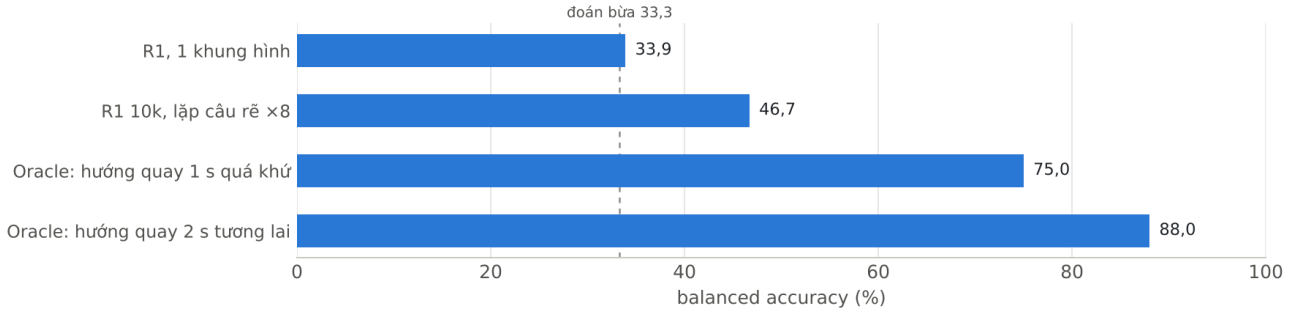
Toàn bộ P2 val	Accuracy	Balanced acc	Recall rẽ, đúng hướng	Recall rẽ, bất kỳ	Precision rẽ, bất kỳ	Tỷ lệ đoán rẽ
B0	92,8	33,3	0,0	0,0	–	0,0
D1: R1 10k	92,8	33,3	0,0	0,0	–	0,0
R1 (40k)	92,3	33,9	1,2	2,4	22,2	0,8
D×8: 10k, câu rẽ × 8	67,4	46,7	34,9	73,5	15,9	33,2

- Không có oversample, mô hình gần như luôn trả lời "đi thẳng" (D1 trả lời đúng một câu cho cả 1.153 câu). Accuracy 92% che giấu điều này.
- Lặp câu rẽ × 8 giúp phát hiện "có rẽ" tốt hơn đoán bừa: bắt 73,5% câu rẽ khi chỉ đoán rẽ 33,2% số câu, precision 15,9% so với tỷ lệ nền 7,2%. Nhưng hướng rẽ ngang tung đồng xu: đúng hướng ở 29/61 câu bắt được (48%). Cái giá là accuracy giảm từ 92,8% xuống 67,4%.

Oracle: nhãn rẽ phụ thuộc quá khứ hay tương lai? Với mỗi câu P2 có vật thể nối được với nuScenes, tính thay đổi góc quay (yaw) của box trong 1–3 giây trước và sau keyframe theo chuỗi annotation trước/sau. Một luật ngưỡng (|Δyaw| ≥ ngưỡng → rẽ, dấu cho biết trái/phải) được chọn ngưỡng trên train và chấm trên val. Quá khứ và tương lai của cùng một khoảng thời gian được chấm trên cùng tập câu hỏi.

Bảng 13. Oracle trên hướng quay thật của box nuScenes. Train: 7.540 câu P2 nối được; val: 1.145.

Cửa sổ	Ngưỡng (°)	Balanced acc	Recall rẽ, đúng hướng	Tỷ lệ đoán rẽ	Số câu val
Quá khứ 1 s	3	75,0	74,0	25,8	1.099
Tương lai 1 s	3	83,8	85,7	24,2	1.099
Quá khứ 2 s	5	74,9	75,0	26,1	835
Tương lai 2 s	7	88,0	91,1	21,8	835
Quá khứ 3 s	8	73,3	70,8	23,9	669
Tương lai 3 s	12	86,2	87,5	20,8	669



Hình 4. Balanced accuracy trên P2: mô hình một khung hình so với oracle. Oracle chấm trên các câu có đủ khung hình (1.099 câu với 1 s, 835 câu với 2 s).

- **Nhãn dựa một phần vào tương lai:** ở mọi khoảng thời gian, tương lai giải thích nhãn tốt hơn quá khứ 9–13 điểm. Một phần P2 thực chất là câu hỏi dự đoán.
- **Quá khứ đã chứa nhiều thông tin:** biết hướng quay thật trong 1 giây vừa qua đạt 75,0, so với 33,9 của R1. Mô hình chỉ có camera phải tự ước lượng hướng xe từ ảnh, nên 75 là trần trên chứ chưa phải mức chắc đạt được. Khoảng cách này là lý do định lượng cho đầu vào nhiều khung hình ở giai đoạn 2.
- **Quy ước trái/phải:** 93% câu rẽ trên train (góc quay vượt ngưỡng) quay đúng chiều của nhãn, tức nhãn dùng hướng trái/phải của chính vật thể.

9. Phân tích lỗi

Từ mẫu kiểm tra tay 100 câu và các bảng nhầm lẫn:

- **P6, nhóm hỗn hợp.** Khi đáp án là "vài xe đỗ, vài xe chạy" (7/20 câu trong mẫu), R1 luôn trả lời một trạng thái duy nhất và sai cả 7. Đây là nguyên nhân chính khiến P6 thấp nhất và có khoảng tin cậy rộng nhất.
- **P5, bỏ sót hơn là bịa.** Trong 20 câu, R1 bỏ sót 15 loại vật thể và chỉ thêm sai 2. Mô hình thường kể loại phổ biến (car) và quên loại hiếm (pedestrian, truck, barrier).
- **P1, toạ độ còn lệch.** F1 tăng từ 44,6 lên 61,3 khi nới ngưỡng từ 50 lên 200 px. Một token ảnh phủ khoảng 115 × 130 px ảnh gốc, nên ngưỡng 50 px nhỏ hơn nửa ô token; sai số dưới một ô token là giới hạn tự nhiên của độ phân giải đầu vào.
- **P2o, đỗ hay đang dừng.** Lỗi chủ yếu là nhầm xe đỗ với xe dừng tạm, vốn cần chuyển động để phân biệt; cùng giới hạn với P2.
- **P3, khác biệt nhãn.** Lỗi còn lại chủ yếu là SUV so với truck và van so với truck, trùng với những chỗ nhãn DriveLM và nuScenes cũng không thống nhất (mục 3.3).

10. Chi phí và khả năng triển khai

Bảng 14. Chi phí trên RTX 5060 Ti 16 GB, batch 1, bf16, greedy.

	R1 (6 ảnh)	R2 (lưới)	T (không ảnh)	Chỉ CAM_FRONT	B2 zero-shot
Token ảnh	588	630	0	98	588
Latency p50 (s)	0,222	0,244	0,102	0,123	0,461
VRAM khi suy luận (GB)	4,22	4,23	4,06	4,08	4,12
Thời gian train (giờ, 2.500 bước)	4,2	5,0	1,7	–	–

Latency của R1 thấp hơn B2 dù cùng mô hình nền, vì R1 học kiểu trả lời ngắn của DriveLM trong khi B2 viết dài; phần prefill (588 token ảnh) gần như bằng nhau. Với 0,22 giây mỗi câu hỏi trên GPU phổ thông, mô hình phù hợp cho phân tích off-board (gán nhãn, kiểm tra dữ liệu, giải thích tình huống). Để chạy on-board cần thêm: đo tách prefill/decode, lượng tử hoá, và trả lời nhiều câu hỏi trong một lần đọc ảnh. Các việc này nằm trong kế hoạch giai đoạn 2.

11. Tính tái lập và đảm bảo chất lượng

- **Mỗi thí nghiệm một config** (kế thừa qua _base_), mỗi run một thư mục `runs/MMDD_exp_d1_sSEED/` chứa config đã gộp, lệnh chạy, commit, phiên bản thư viện, câu trả lời và báo cáo điểm.
- **43 test**, gồm một lần chạy đầu cuối trên dữ liệu tổng hợp đúng định dạng DriveLM/nuScenes.
- **Kiểm tra toàn vẹn** (`scripts/check_runs.py`): 14 run trên tập val cố định có cùng mã băm tập câu hỏi (kể cả sau khi dựng lại dữ liệu); số token ảnh, seed, số mẫu train và nguồn adapter khớp config; mỗi run có câu trả lời riêng. Cặp trùng duy nhất là hai mô hình cùng trả lời "Going ahead." cho mọi câu.
- **Đối chiếu báo cáo** (`make verify`): chạy lại test, kiểm tra run, chấm lại, bootstrap ghép cặp, oracle, bảng, rồi so 239 con số của báo cáo với kết quả tính lại: 239/239 khớp.

Những lỗi đã phát hiện và sửa trong quá trình làm (ghi theo ngày trong `results/log.md`):

- Bộ phân loại câu hỏi viết theo kế hoạch không khớp mẫu câu thật của v1.1; viết lại theo 30 mẫu câu thật.
- "Standing" chưa được hiểu là đứng yên và câu hỏi về người lái xe chưa có nhãn, khiến P6 của B0 bị thổi từ 36,9 lên 53,7. "Road sign" chưa được nhận là biển báo. Đèn giao thông đúng từng bị tính là bịa.
- Hàm tìm run khớp nhầm `r1_10k` với `r1_10k_turnx8`; bảng kết quả từng lấy nhầm run chạy thử 10 câu; config kế thừa từng bị bỏ qua bước train. Cả ba đã sửa và có test.
- Bốn kết luận của chính tác giả bị dữ liệu bác bỏ và đã sửa: "loss phẳng thì thêm dữ liệu ít tác dụng" rồi "thêm dữ liệu giúp" (thực ra do số bước); "lặp câu rẽ học được hướng rẽ" (so sai mốc); "độ lệch ±5–9 là nhiễu ngẫu nhiên" (do đổi dữ liệu train; seed chỉ lệch tối đa 2,7); "P2o gần trần 90%". Các sửa đổi đến từ một vòng phản biện 25 câu và các thí nghiệm kiểm soát chạy sau đó.

12. Hạn chế

- **Cỡ mẫu.** 100 câu val mỗi loại cho khoảng tin cậy ±4–20 điểm. Khác biệt nhỏ chỉ được coi là có thật khi bootstrap ghép cặp cho thấy.
- **Số seed.** Ba seed chỉ có cho R1; R2 và các bản 10k mỗi bản một lần chạy.
- **Khái quát.** Tập val tách theo scene nhưng chung bốn khu vực của nuScenes, nên đo trong phân phối, chưa đo khái quát sang thành phố mới. Qwen3-VL có thể đã thấy ảnh nuScenes khi pretrain; mọi bản so sánh dùng chung backbone nên so sánh nội bộ vẫn công bằng.
- **Bộ chấm.** Dựa trên từ khoá, kiểm tra tay 100 câu bởi chính người viết. Quy ước: trailer và xe công trình gộp vào truck. Thẻ bịa là cận trên: một biển báo có thật mà DriveLM không liệt kê sẽ bị tính bịa.
- **Ablation.** Ablation camera dùng lại checkpoint R1, chưa train riêng. Đánh giá là open-loop, không đo chất lượng lái.

13. Kết luận và hướng tiếp theo

Một VLM 2B tham số, fine-tune bằng LoRA trong khoảng 4 giờ trên một GPU 16 GB, đã chỉ ra được vật thể quan trọng (P1 F1 55,0%, 5,4% thẻ bịa) và trả lời đúng phần lớn câu hỏi về loại và vị trí vật thể. Ba kết luận được kiểm chứng chặt: ảnh đóng góp +19 đến +35 điểm so với cùng công thức không ảnh; mô hình dùng ảnh của đúng camera được hỏi; kết quả ổn định giữa các seed. Ba điều chưa chứng minh được và được nói rõ: P4, tác động của dữ liệu khi cùng số bước, và khác biệt giữa ảnh riêng và ảnh lưới ngoài P3.

Giới hạn rõ nhất là chuyển động: từ một khung hình, mô hình không nhận ra xe đang rẽ, trong khi chuyển động thật của 1 giây quá khứ đã cho balanced accuracy 75%. Kế hoạch giai đoạn 2 (tài liệu riêng) đi theo đúng các phát hiện này: thêm khung hình quá khứ, sửa các lỗi đã biết (P6 hỗn hợp, P5 vật thể hiếm), nối perception với câu hỏi dự đoán và lập kế hoạch, và xuất quỹ đạo 3 giây với baseline chỉ dùng trạng thái xe.

Tài liệu tham khảo

[1] C. Sima và cs. DriveLM: Driving with Graph Visual Question Answering. ECCV 2024.

[2] H. Caesar và cs. nuScenes: A multimodal dataset for autonomous driving. CVPR 2020.

[3] Z. Li và cs. Is Ego Status All You Need for Open-Loop End-to-End Autonomous Driving? CVPR 2024.

[4] X. Zhou và cs. OpenDriveVLA: Towards End-to-end Autonomous Driving with Large Vision Language Action Model. AAAI 2026.

[5] Qwen Team. Qwen3-VL. Mô hình nền Qwen3-VL-2B-Instruct.

[6] E. J. Hu và cs. LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.

[7] Z. Zhou và cs. AutoVLA: A Vision-Language-Action Model for End-to-End Autonomous Driving with Adaptive Reasoning and Reinforcement Fine-Tuning. NeurIPS 2025.

[8] M. Tschannen và cs. SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features. 2025.

Phụ lục A. Cấu hình các thí nghiệm

Bảng 15. Mỗi config chỉ đổi một yếu tố so với R1. Chạy: make run EXP=<config>.

Config	Khác R1 ở	Mẫu train	Bước	Seed	Token ảnh
r1_6cam	–	40.000	2.500	0	588
r1_seed1 / r1_seed2	seed	40.000	2.500	1 / 2	588
r1_textonly	không ảnh, không tắt camera	40.000	2.500	0	0
r2_grid	1 ảnh lưới 3 × 2 (ngân sách pixel 6 lần)	40.000	2.500	0	630
r1_10k	10.000 mẫu	10.000	625	0	588
r1_10k_4ep	10.000 mẫu × 4 epoch	10.000	2.500	0	588
r1_10k_turnx8	10.000 mẫu, câu rẽ P2 lặp × 8 trước khi lấy mẫu	10.000	625	0	588
abl_front_only / abl_no_camname	checkpoint R1; chỉ CAM_FRONT / bỏ tên camera	–	–	0	98 / 588
b2_zeroshot / b2_fewshot	không train; few-shot: 2 câu trả lời mẫu mỗi loại	–	–	0	588
p2full_*	P2 trên toàn bộ 1.153 câu val	–	–	0	–

Phụ lục B. Khoảng tin cậy và nhãn sạch

Bảng 16. Khoảng tin cậy 95%, bootstrap theo scene (1.000 lần).

Mô hình	P1 F1	Bịa	P2o	P3	P4	P5	P6
B0	–	–	39,4 [34,8; 42,7]	60,7 [49,0; 71,3]	73,1 [63,5; 81,9]	56,7 [50,1; 63,4]	36,9 [28,7; 52,5]
B2 zero-shot	0,0	–	32,7 [22,0; 43,5]	68,5 [58,3; 78,5]	59,3 [48,2; 69,8]	21,8 [15,3; 28,5]	8,1 [4,6; 13,8]
B2 few-shot	3,3 [1,5; 5,7]	54,6 [43,3; 66,7]	35,9 [26,1; 45,6]	60,7 [49,4; 71,3]	63,0 [51,6; 73,7]	64,0 [59,1; 68,9]	13,5 [8,2; 23,0]
T: không ảnh	19,7 [14,8; 24,6]	19,0 [12,1; 26,7]	61,8 [51,6; 71,4]	70,8 [60,6; 80,9]	71,7 [62,2; 80,6]	59,2 [53,1; 65,3]	34,6 [25,8; 50,6]
R1 seed 0	55,0 [50,0; 59,5]	5,4 [3,3; 7,8]	80,9 [72,7; 88,5]	91,0 [85,2; 96,6]	80,8 [71,4; 89,3]	79,7 [75,4; 83,3]	53,6 [35,6; 76,5]
R1 seed 1	54,9 [50,2; 59,7]	4,8 [2,6; 7,3]	82,4 [73,4; 90,3]	89,9 [83,3; 95,5]	80,0 [69,4; 89,1]	79,3 [74,0; 84,0]	55,4 [37,3; 78,1]
R1 seed 2	54,2 [49,9; 58,7]	6,8 [4,7; 9,2]	82,2 [73,3; 90,2]	88,8 [82,3; 94,6]	81,5 [71,8; 89,9]	77,1 [73,5; 80,4]	52,7 [34,9; 75,2]
R2	54,9 [49,6; 59,8]	5,7 [3,2; 8,9]	79,3 [70,0; 87,8]	84,3 [75,0; 92,2]	77,3 [66,5; 87,8]	76,6 [72,1; 80,8]	47,0 [33,1; 70,2]
D4: 10k × 4	55,1 [50,2; 60,2]	5,4 [3,0; 7,6]	73,6 [62,8; 83,5]	86,5 [78,1; 93,3]	80,8 [70,9; 89,8]	77,4 [73,0; 81,4]	50,1 [33,1; 73,7]

Bảng 17. Điểm trên toàn bộ câu và trên tập "sạch" (bỏ câu có nhãn DriveLM mâu thuẫn nuScenes). Thứ hạng không đổi.

Mô hình	P2 acc: tất cả / sạch	P2o acc: tất cả / sạch	P4 b-acc: tất cả / sạch	P3: theo DriveLM / theo nuScenes
B0	91,0 / 90,1	65,0 / 65,9	73,1 / 74,9	60,7 / 64,4
T: không ảnh	91,0 / 90,1	64,0 / 64,8	71,7 / 72,8	70,8 / 72,4
R1 seed 0	90,0 / 89,0	83,0 / 84,6	80,8 / 81,1	91,0 / 92,0
R1 seed 1	91,0 / 90,1	84,0 / 83,5	80,0 / 79,7	89,9 / 90,8
R1 seed 2	90,0 / 89,0	84,0 / 84,6	81,5 / 81,1	88,8 / 89,7
R2	89,0 / 87,9	82,0 / 83,5	77,3 / 76,9	84,3 / 85,1

Phụ lục C. Điểm theo camera được hỏi

Bảng 18. "Trước" = câu hỏi về CAM_FRONT, "khác" = 5 camera còn lại (P4: 27 / 73 câu).

Mô hình	P2o trước / khác	P3 trước / khác	P4 trước / khác	P5 trước / khác	P6 trước / khác
B0	40,5 / 38,4	58,7 / 62,8	79,2 / 72,3	69,4 / 52,0	43,8 / 38,6
T: không ảnh	55,5 / 58,4	67,4 / 74,4	79,2 / 70,9	73,3 / 53,1	28,2 / 37,1
R1 seed 0	70,0 / 88,2	87,0 / 95,3	95,8 / 78,5	83,0 / 78,6	59,5 / 58,3
R1 chỉ CAM_FRONT	66,4 / 61,6	87,0 / 51,2	95,8 / 71,3	84,1 / 60,9	59,5 / 36,6
R1 bỏ tên camera	75,5 / 78,8	82,6 / 74,4	95,8 / 67,1	76,9 / 71,1	58,7 / 38,6
R2	68,3 / 86,1	82,6 / 86,1	95,8 / 74,7	78,5 / 76,0	56,8 / 39,9

Phụ lục D. Lệnh tái lập

`make data` (dựng dữ liệu, kiểm tra nhãn) → `make run EXP=<config>` (train, suy luận, chấm) → `make paired` (so sánh ghép cặp) → `make label-oracle` (oracle nhãn rẽ) → `make tables` → `make verify` (kiểm tra mọi con số của báo cáo, khoảng 10 phút, chỉ CPU). Dữ liệu DriveLM (CC BY-NC-SA 4.0) và nuScenes (điều khoản phi thương mại) không nằm trong repo; hướng dẫn tải ở README.