Kế hoạch giai đoạn 2: từ perception đến dự đoán và lập quỹ đạo

11/11/2026 · Tran Thanh Dat · tiếp nối báo cáo giai đoạn 1 (perception) · thời lượng dự kiến 4 tuần + 2 ngày chuẩn bị, trên một GPU 16 GB (RTX 5060 Ti)

Mục tiêu. Biến mô hình perception của giai đoạn 1 thành một mô hình vision-language-action nhỏ: nhìn nhiều khung hình, trả lời câu hỏi dự đoán/lập kế hoạch của DriveLM, và xuất quỹ đạo 3 giây của xe. Mọi bước vẫn theo nguyên tắc của giai đoạn 1: **đầu ra nào kiểm chứng được bằng dữ liệu nuScenes thì kiểm chứng**; luôn có baseline không ảnh hoặc chỉ dùng trạng thái xe; so sánh bằng bootstrap ghép cặp; có điểm quyết định sau mỗi bước để dừng hướng không hiệu quả.

1. Xuất phát điểm: giai đoạn 1 cho biết gì

Kết quả giai đoạn 1	Hệ quả cho giai đoạn 2
R1 định vị vật thể tốt (P1 F1 55,0; ảnh đóng góp +35 so với bản không ảnh) và dùng ảnh của đúng camera được hỏi.	Giữ nguyên backbone, LoRA và 6 ảnh riêng có tên camera làm nền; không cần thiết kế lại phần nhìn.
Một khung hình không đủ cho chuyển động: balanced accuracy câu rẽ 33,9; lặp câu rẽ ×8 chỉ đoán đúng hướng 48%.	Thêm khung hình quá khứ là ưu tiên số 1 (hạng mục A).
Oracle trên hướng quay thật: 75,0 từ 1 giây quá khứ, 88,0 từ 2 giây tương lai. Nhãn rẽ dựa một phần vào tương lai.	Trần thực tế cho đầu vào quá khứ khoảng 75. Phần còn lại là bài toán dự đoán, nên nối với hạng mục C, D.
Bản không ảnh đã tăng P2o 22 điểm so với B0; ba seed lệch tối đa 2,7; tập val 100 câu mỗi loại cho khoảng tin cậy ±4–20.	Mọi thí nghiệm có baseline không ảnh hoặc chỉ dùng trạng thái xe; mở rộng tập val; 3 seed cho so sánh chính.
Lỗi còn lại: P6 nhóm hỗn hợp (0/7), P5 bỏ sót vật thể hiếm, toạ độ P1 lệch.	Sửa bằng cân bằng dữ liệu và chọn ngưỡng, không cần mô hình mới (hạng mục B).

2. Câu hỏi nghiên cứu

- **RQ1. Chuyển động:** thêm 2 khung hình quá khứ (0,5 s và 1 s trước) giúp VLM nhận ra xe đang rẽ và phân biệt xe đỗ với xe đang dừng đến mức nào, so với trần oracle 75?
- **RQ2. Từ perception đến quyết định:** khi trả lời câu hỏi dự đoán và lập kế hoạch, dùng câu trả lời perception của chính mô hình thay cho đáp án thật làm mất bao nhiêu điểm? Lỗi perception lan sang quyết định như thế nào?
- **RQ3. Quỹ đạo:** VLM xuất quỹ đạo 3 giây có tốt hơn baseline chỉ dùng trạng thái xe (vận tốc, gia tốc) không? Đây là cái bẫy đã biết của đánh giá open-loop trên nuScenes [3]: mô hình chỉ dùng trạng thái xe đã đạt kết quả cạnh tranh, nên phải có baseline này.

3. Các hạng mục

A. Đầu vào nhiều khung hình (RQ1) · tuần 1–2

- **A0, oracle bằng chữ** (chỉ đánh giá, khoảng 2 giờ GPU): đưa thay đổi góc quay thật vào prompt ("vật thể quay +12° trong 1 giây qua"). Nếu VLM không dùng được thông tin chuyển động *khi được cho sẵn bằng chữ*, thì khó mong nó tự rút ra từ ảnh. Thí nghiệm này rẻ và quyết định hướng đi.
- **A1, quá khứ cho camera được hỏi:** thêm ảnh t − 0,5 s và t − 1 s của camera mà câu hỏi nhắc tới (thêm khoảng 196 token, train chậm hơn khoảng 1,3 lần). Biến thể nhẹ nhất, nhắm trực tiếp vào P2 và P2o.
- **A2, quá khứ cho cả 6 camera** ở độ phân giải thấp hơn (khoảng 1.200–1.800 token). Chỉ chạy nếu A1 có ích, vì chi phí gấp khoảng 2–3 lần.
- **Đo:** P2 trên toàn bộ 1.153 câu val (balanced accuracy, recall và precision câu rẽ, đúng hướng); P2o tách riêng nhầm lẫn "đỗ" và "đang dừng"; kiểm tra P1, P3–P6 không bị giảm. So với R1 bằng bootstrap ghép cặp.
- **Dữ liệu cần thêm:** gói ảnh của DriveLM chỉ chứa các keyframe có câu hỏi, không có khung hình trước đó. Cần tải ảnh camera nuScenes trainval (các phần blob chứa cả sweep). Kiểm tra dung lượng trước khi tải; có thể bắt đầu với 1–2 phần (mỗi phần khoảng 1/10 số scene).

B. Sửa các lỗi đã biết · tuần 2 (song song với A)

- **Chọn ngưỡng cho P2 không cần train:** tính xác suất mô hình gán cho từng lựa chọn ("Going ahead", "Turn left", "Turn right"), chọn ngưỡng trên một phần tập train để đổi giữa recall và precision câu rẽ. So với oversample ×8 (precision 15,9%).
- **P6 nhóm hỗn hợp:** tăng tỷ lệ câu có đáp án hỗn hợp ("vài xe đỗ, vài xe chạy") khi lấy mẫu. **P5 vật thể hiếm:** lấy mẫu cân bằng theo loại vật thể trong đáp án. Mỗi thay đổi một run 40k (khoảng 4 giờ) và so ghép cặp với R1.

C. Chuỗi perception → dự đoán → lập kế hoạch (RQ2) · tuần 3

- DriveLM-nuScenes còn ba nhóm câu hỏi chưa dùng: dự đoán ("vật thể này có nằm trên hướng đi của xe không?"), lập kế hoạch ("xe nên làm gì với vật thể này?") và hành vi xe ("xe đang đi thẳng, chạy chậm") [1].
- **Kiểm chứng bằng nuScenes như giai đoạn 1:** nhãn hành vi xe so được với quỹ đạo ego thật (vận tốc, góc lái trong vài giây tới); câu "có nằm trên hướng đi không" so được với vị trí box và quỹ đạo ego tương lai. Những câu kiểm chứng được sẽ có bộ chấm riêng; câu tự do chỉ báo cáo kèm cảnh báo.
- **Thí nghiệm chuỗi:** train trên cả perception và các nhóm mới; khi đánh giá, đưa vào ngữ cảnh (a) đáp án perception thật, (b) câu trả lời perception của chính mô hình, (c) không có ngữ cảnh. Hiệu (a) − (b) là lượng lỗi lan truyền; (b) − (c) cho biết chuỗi có ích không.

D. Xuất quỹ đạo 3 giây (RQ3) · tuần 3–4

- **Nhãn:** 6 điểm quỹ đạo ego (2 Hz, 3 giây) trong hệ toạ độ xe, lấy từ ego pose của nuScenes (đã có trong metadata). **Đầu vào:** 6 camera, lệnh điều hướng (rẽ trái / đi thẳng / rẽ phải, suy từ điểm cuối quỹ đạo như các công trình trước), và tuỳ biến thể có hay không có trạng thái xe.
- **Đầu ra:** trước hết dạng văn bản ("(x1, y1), ..., (x6, y6)"), giữ nguyên cách sinh của VLM. Nếu kịp, so với một đầu MLP nhỏ đọc trạng thái ẩn của VLM.
- **Đo:** sai số L2 ở 1/2/3 giây và tỷ lệ va chạm với box nuScenes ở các thời điểm tương lai (tự cài đặt, dùng box đã có). **Baseline bắt buộc:** vận tốc không đổi; MLP chỉ dùng trạng thái xe [3]; VLM không có trạng thái xe; VLM có trạng thái xe.
- **Dữ liệu:** 4.072 keyframe của DriveLM là ít cho quỹ đạo. Nếu đã tải ảnh nuScenes ở hạng mục A, dùng thêm toàn bộ keyframe trainval (nhãn quỹ đạo có sẵn cho mọi keyframe).
- **Không làm trong 4 tuần:** NAVSIM v2 [5]. Đây là benchmark gần closed-loop hơn, chấm bằng EPDMS với pseudo-simulation [6], nhưng cần dữ liệu OpenScene/nuPlan lớn. Ghi vào hướng tiếp theo.

E. Đánh giá và triển khai · xuyên suốt

- **Tập val lớn hơn:** chấm các loại câu đóng trên toàn bộ khoảng 20.000 câu val thay vì 700, thu hẹp khoảng tin cậy từ ±4–20 xuống khoảng ±1–3 điểm. Chi phí khoảng 75 phút GPU cho mỗi mô hình.
- **3 seed** cho mọi so sánh dùng để kết luận; bootstrap ghép cặp theo scene; `make verify` mở rộng cho các con số của báo cáo giai đoạn 2.
- **Ngân sách on-board:** đo latency tách prefill và decode, số token đầu ra của quỹ đạo, bộ nhớ đỉnh. Nếu còn thời gian, thử lượng tử hoá 4/8 bit và báo cáo độ giảm điểm tương ứng.

4. Lịch và ngân sách GPU

Thời gian	Việc chính	GPU (ước tính)	Kết thúc khi có
Chuẩn bị (2 ngày)	Tải ảnh nuScenes (1–2 phần trước); chỉ mục khung hình quá khứ; nhãn quỹ đạo ego; chấm R1 trên toàn bộ val	khoảng 2 giờ	R1 trên toàn bộ val; dữ liệu nhiều khung hình kiểm tra được
Tuần 1	A0 oracle bằng chữ; A1 quá khứ cho camera được hỏi (3 seed)	khoảng 16 giờ	Điểm quyết định G1, G2
Tuần 2	A2 nếu A1 có ích; B: chọn ngưỡng P2, cân bằng P5/P6	khoảng 20 giờ	Cấu hình perception cuối
Tuần 3	C: bộ chấm cho dự đoán/hành vi; train và thí nghiệm chuỗi; bắt đầu D	khoảng 10 giờ	Lượng lỗi lan truyền (a) − (b)
Tuần 4	D: quỹ đạo, 4 biến thể và baseline; báo cáo giai đoạn 2	khoảng 12 giờ	Bảng L2 / va chạm; báo cáo; make verify

Tổng khoảng 60 giờ GPU, chủ yếu chạy qua đêm như giai đoạn 1 (mỗi run 40k khoảng 4,2 giờ). Thời gian thêm do nhiều khung hình được tính theo số token tăng thêm.

5. Điểm quyết định

Điểm	Khi nào	Tiêu chí	Nếu không đạt
G1	Cuối tuần 1	A0: có thông tin chuyển động bằng chữ, balanced accuracy P2 ≥ 60	VLM không dùng được chuyển động ngay cả khi được cho sẵn: dừng A2, báo cáo kết quả âm, chuyển sang C và D
G2	Cuối tuần 1	A1: balanced accuracy P2 ≥ 50 và precision câu rẽ (bất kỳ) ≥ 22%, tức gấp 3 tỷ lệ nền và hơn mức 15,9% của bản lặp ×8; không giảm P1/P3–P6 (ghép cặp)	Giữ một khung hình cho các bước sau; ghi rõ khoảng cách tới oracle
G3	Tuần 4	VLM tốt hơn vận tốc không đổi ở L2 3 giây và không kém MLP chỉ dùng trạng thái xe; tỷ lệ va chạm không cao hơn	Báo cáo trung thực như Li và cs. [3]; phân tích tình huống VLM có lợi (rẽ, gặp vật cản)

6. Rủi ro và cách giảm

Rủi ro	Cách giảm
Dung lượng và thời gian tải ảnh nuScenes	Kiểm tra dung lượng trước; bắt đầu với 1–2 phần; A1 chỉ cần khung hình quá khứ của các scene có trong DriveLM
Hết bộ nhớ GPU khi thêm khung hình	A1 chỉ thêm ảnh của một camera; giảm độ phân giải ảnh quá khứ; batch 1, gradient checkpointing như giai đoạn 1
Đánh giá open-loop trên nuScenes thiên về trạng thái xe	Baseline chỉ dùng trạng thái xe và vận tốc không đổi là bắt buộc; báo cáo tỷ lệ va chạm cạnh L2; tách tình huống rẽ
Nhãn rẽ dựa một phần vào tương lai	Báo cáo kết quả so với cả oracle quá khứ (75) và oracle tương lai (88), không chỉ so với 100
Quá ít dữ liệu quỹ đạo nếu chỉ dùng keyframe DriveLM	Mở rộng sang mọi keyframe trainval khi có ảnh; nếu không, báo cáo như thí nghiệm ít dữ liệu
Không đủ 4 tuần	Thứ tự bỏ: A2 → đầu MLP cho quỹ đạo → lượng tử hoá. Giữ A0, A1, C, D cơ bản

7. Sản phẩm bàn giao

- Mã nguồn mở rộng từ repo giai đoạn 1: dữ liệu nhiều khung hình, nhãn quỹ đạo, bộ chấm hành vi/dự đoán, chấm quỹ đạo (L2, va chạm), mỗi thí nghiệm một config.
- Báo cáo giai đoạn 2 cùng định dạng: bảng chính, so sánh ghép cặp, điểm quyết định đã đạt hay không, kết quả âm nếu có.
- `make verify` kiểm tra mọi con số của báo cáo giai đoạn 2.

Tài liệu tham khảo

[1] C. Sima và cs. DriveLM: Driving with Graph Visual Question Answering. ECCV 2024.

[2] H. Caesar và cs. nuScenes: A multimodal dataset for autonomous driving. CVPR 2020.

[3] Z. Li và cs. Is Ego Status All You Need for Open-Loop End-to-End Autonomous Driving? CVPR 2024.

[4] X. Zhou và cs. OpenDriveVLA: Towards End-to-end Autonomous Driving with Large Vision Language Action Model. AAAI 2026.

[5] D. Dauner và cs. NAVSIM: Data-Driven Non-Reactive Autonomous Vehicle Simulation and Benchmarking. NeurIPS 2024.

[6] W. Cao và cs. Pseudo-Simulation for Autonomous Driving (NAVSIM v2). CoRL 2025.

[7] Z. Zhou và cs. AutoVLA: A Vision-Language-Action Model for End-to-End Autonomous Driving with Adaptive Reasoning and Reinforcement Fine-Tuning. NeurIPS 2025.

[8] Qwen Team. Qwen3-VL (mô hình nền dùng trong giai đoạn 1).