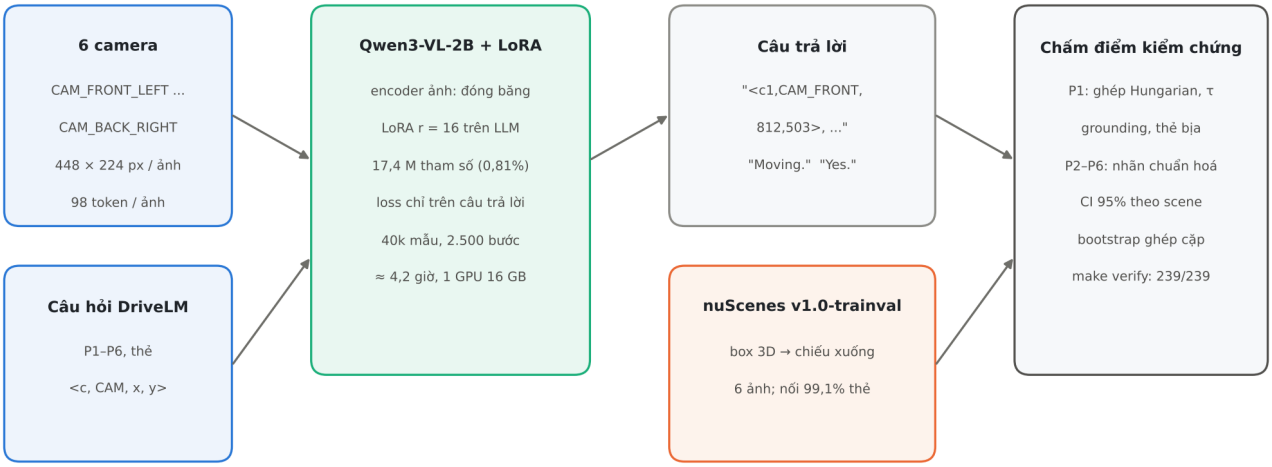
Nhìn đúng trước khi lái: kiểm chứng perception của một VLM đa camera trên DriveLM-nuScenes bằng nhãn 3D

Tran Thanh Dat

Technical report giai đoạn 1 · 11/2026 · mã nguồn và lệnh tái lập: `drivelm-perception-vlm`

Tóm tắt

Các mô hình lái xe dựa trên VLM thường được đánh giá bằng độ giống chữ hoặc bằng một LLM khác, nên khó biết mô hình có thật sự nhìn đúng cảnh hay không. Chúng tôi xây dựng một quy trình đánh giá trong đó mọi câu trả lời perception của DriveLM-nuScenes được đối chiếu với box 3D của nuScenes chiếu xuống ảnh, và dùng nó để nghiên cứu một VLM nhỏ fine-tune trên phần cứng phổ thông. Qwen3-VL-2B, fine-tune bằng LoRA (0,81% tham số) trên 40.000 câu hỏi với 6 ảnh camera trong khoảng 4,2 giờ trên một GPU 16 GB, đạt F1 54,7 ± 0,4 khi chỉ ra vật thể quan trọng (mô hình gốc: 0) với 5,7 ± 1,0% thẻ bịa, và 89,9 ± 1,1% khi nhận dạng loại vật thể (trung bình ± độ lệch chuẩn trên 3 seed). Thí nghiệm kiểm soát với cùng công thức nhưng không có ảnh cho thấy ảnh đóng góp +19 đến +35 điểm và chỉ một phần mức tăng so với baseline đến từ ảnh; ablation theo camera xác nhận mô hình dùng ảnh của đúng camera được hỏi. Mức tăng tưởng như do thêm dữ liệu hoá ra do train nhiều bước hơn. Giới hạn chính là chuyển động: từ một khung hình, mô hình không nhận ra xe đang rẽ (balanced accuracy 33,9), trong khi một oracle dùng hướng quay thật trong 1 giây quá khứ đạt 75,0, và nhãn rẽ của DriveLM phụ thuộc một phần vào tương lai. Mọi con số trong báo cáo tóm tắt kèm theo được kiểm tra lại tự động bằng một lệnh.



Hình 1. Tổng quan. Một VLM nhỏ nhận 6 ảnh camera có tên và một câu hỏi DriveLM, trả lời bằng chữ và thẻ vật thể <c, CAM, x, y>. Thay vì so chữ với đáp án, câu trả lời được chấm theo nghĩa vật lý: thẻ được đối chiếu với box 3D của nuScenes chiếu xuống ảnh, mọi so sánh kèm khoảng tin cậy bootstrap theo scene.

1. Giới thiệu

Lái xe end-to-end dựa trên mô hình ngôn ngữ–thị giác (VLM) hứa hẹn gộp hiểu cảnh, lập luận và hành động vào một mô hình [4, 9, 10]. Muốn tin vào quyết định của một mô hình như vậy, trước hết cần biết nó có *nhìn đúng* không: vật thể quan trọng ở đâu, là gì, đang làm gì. Các benchmark câu hỏi–trả lời về lái xe như DriveLM [1] hay NuScenes-QA [11] cung cấp những câu hỏi này, nhưng phần câu trả lời tự do thường được chấm bằng độ giống chữ hoặc bằng một LLM khác. Hai cách này đo việc mô hình nói giống đáp án, không đo việc mô hình thấy đúng.

Báo cáo này đặt perception làm đối tượng nghiên cứu riêng, trước khi thêm dự đoán và hành động. Chúng tôi trả lời ba câu hỏi: (i) một VLM 2B tham số, fine-tune trên một GPU phổ thông, định vị được vật thể quan trọng tốt đến đâu và bịa ra bao nhiêu; (ii) bao nhiêu phần điểm số thật sự đến từ ảnh; (iii) những gì không suy ra được từ một khung hình, và trần trên nếu có thêm thông tin chuyển động.

Đóng góp:

- **Quy trình đánh giá kiểm chứng được.** Nối 99,1% thẻ vật thể của DriveLM với box 3D của nuScenes; đo mức khớp của nhãn DriveLM (trạng thái 89,7%, loại vật thể 94,3%, có/không theo vùng 93,7%); chấm câu trả lời theo nghĩa vật lý với định nghĩa thẻ bịa không phạt oan đèn và biển báo.
- **Một mô hình nhỏ, rẻ, định vị được vật thể:** P1 F1 54,7 ± 0,4 với 5,7 ± 1,0% thẻ bịa, train trong khoảng 4,2 giờ trên GPU 16 GB.
- **Một bộ thí nghiệm kiểm soát** tách phần nhờ ảnh khỏi phần nhờ câu hỏi (LoRA không ảnh), dữ liệu khỏi số bước train, và đo nhiễu giữa các seed; mọi so sánh kèm khoảng tin cậy ghép cặp theo scene. Hai kết luận trực giác bị bác bỏ: không phải toàn bộ mức tăng so với baseline đến từ ảnh, và không phải thêm dữ liệu mà là thêm bước train.
- **Một phân tích oracle về chuyển động** cho thấy nhãn rẽ của DriveLM phụ thuộc một phần vào tương lai (88,0 so với 74,9) và đo được lượng thông tin có trong chuyển động quá khứ.
- **Tái lập đầy đủ:** 43 test, kiểm tra toàn vẹn mọi run, và một lệnh đối chiếu 239 con số của báo cáo tóm tắt với kết quả tính lại.

2. Công trình liên quan

Câu hỏi–trả lời cho lái xe. DriveLM [1] tổ chức hiểu cảnh thành chuỗi perception → prediction → planning trên ảnh nuScenes [2], tham chiếu vật thể bằng thẻ toạ độ, nhờ vậy có thể nối với nhãn 3D. NuScenes-QA [11] sinh câu hỏi từ nhãn cảnh. Khác với các công trình này, chúng tôi không đề xuất benchmark mới mà đổi cách chấm: câu trả lời perception được kiểm chứng bằng nhãn 3D, kèm kiểm toán chính nhãn của benchmark.

VLM và VLA cho lái xe. DriveVLM [9], EMMA [10], OpenDriveVLA [4] và AutoVLA [7] dùng VLM lớn để sinh quỹ đạo và trả lời câu hỏi, đánh giá trên nuScenes, Waymo hoặc NAVSIM. Chúng tôi cố ý dùng mô hình 2B và một GPU 16 GB, và dừng ở perception, để đo kỹ những gì mô hình nhìn được trước khi thêm hành động.

Ảo giác và đánh giá có kiểm soát. POPE [12] đo ảo giác vật thể của VLM bằng câu hỏi có/không. Chúng tôi đo ảo giác ở mức không gian: một thẻ là bịa khi không có vật thể nào tại điểm đó. Li và cs. [3] chỉ ra rằng trên nuScenes, mô hình end-to-end có trạng thái xe chủ yếu dựa vào trạng thái đó để lập quỹ đạo. Bài học tương tự cho perception là cần baseline không dùng ảnh; chúng tôi dùng hai baseline như vậy.

3. Bài toán và dữ liệu

3.1 Bài toán

Mỗi mẫu gồm 6 ảnh camera $I = \{I_c\}$ của một keyframe, một câu hỏi q và một câu trả lời đích a. Mô hình sinh câu trả lời $\hat{a}$; một hàm chuẩn hoá g theo loại câu hỏi rút ra nhãn có cấu trúc (tập thẻ, nhãn trạng thái, có/không, tập loại vật thể). Điểm được tính trên $g(\hat{a})$ so với $g(a)$, và với P1 còn so với box 3D của nuScenes.

3.2 Dữ liệu và cách chia

Dùng nhóm câu hỏi perception của DriveLM-nuScenes v1.1 (162.480 câu, 4.072 keyframe, 696 scene) cùng metadata nuScenes v1.0-trainval. Dữ liệu được chia theo scene: 605 scene train (141.808 câu) và 91 scene val (20.672 câu), không scene nào xuất hiện ở cả hai phía. 30 mẫu câu được gom thành 7 loại chấm được (Bảng 1). Tập val cố định gồm 100 câu mỗi loại từ P1 đến P6 (700 câu), dùng chung cho mọi mô hình; P2 còn được chấm trên toàn bộ 1.153 câu val vì câu rẽ chỉ chiếm 7,2%.

Bảng 1. Phân loại câu hỏi perception. Vùng (front left, back, ...) tương ứng một camera.

Loại	Câu hỏi	Train	Val	Chỉ số
P1	Vật thể quan trọng trong cảnh	3.543	529	F1 sau ghép Hungarian (τ = 100 px), grounding, thẻ bịa
P2	Trạng thái di chuyển của <tag>	7.624	1.153	Balanced accuracy; recall/precision câu rẽ
P2o	Trạng thái quan sát của <tag>	13.439	1.944	Macro-F1 (đang chạy / đứng yên)
P3	Mô tả hình ảnh của <tag>	15.087	2.195	Accuracy loại vật thể
P4	Có {trạng thái} {loại} ở {vùng} không?	40.343	5.874	Balanced accuracy
P5	Những vật thể nào ở {vùng}?	17.450	2.535	F1 trên tập loại vật thể
P6	Trạng thái của các {loại} ở {vùng}	33.086	4.742	Macro-F1
other	Mô tả cảnh, vị trí, làn đường, đèn/biển báo	11.236	1.700	Chỉ dùng khi train

3.3 Kiểm toán nhãn bằng nuScenes

Box 3D của nuScenes được chiếu xuống 6 ảnh. Mỗi thẻ DriveLM được nối với box có IoU lớn nhất với box 2D mà DriveLM cung cấp, nếu không thì với box chứa điểm thẻ. Kết quả (Bảng 2) cho thấy khoảng một nhãn trong mười mâu thuẫn với nhãn 3D. Các câu này được đánh dấu và chấm riêng (Phụ lục C); mô hình vẫn được chấm theo nhãn DriveLM vì đó là nhãn nó học.

Bảng 2. Kiểm toán nhãn DriveLM bằng nhãn 3D của nuScenes.

Kiểm tra	Kết quả	Nguyên nhân chính của phần không khớp
Thẻ nối được với box	99,1%	Đèn và biển báo (1.875 thẻ) không có box trong nuScenes; nhóm Others 86,9%
Trạng thái khớp	89,7%	DriveLM gọi xe dừng tạm là "Stationary" (79,8% nếu tính dừng tạm là đang chạy)
Loại vật thể khớp	94,3%	Khác biệt thật giữa hai bộ nhãn: SUV hay truck, truck hay bus
Có/không theo vùng khớp	93,7%	DriveLM đếm cả vật thể khó thấy; "parked" bao gồm xe dừng tạm

4. Phương pháp

Mô hình. Qwen3-VL-2B-Instruct [5]. Đầu vào là một câu hệ thống mô tả quy ước thẻ, sau đó 6 ảnh camera theo thứ tự cố định, mỗi ảnh kèm tên camera, rồi câu hỏi. Mỗi ảnh được thu về ngân sách 448 × 252 px, tương ứng 98 token sau khi làm tròn theo lưới patch (588 token cho 6 camera; một token phủ khoảng 115 × 130 px ảnh gốc).

Huấn luyện. LoRA [6] với r = 16, α = 32 trên các phép chiếu attention và MLP của phần ngôn ngữ; encoder ảnh đóng băng. Hàm mất mát là log-likelihood âm chỉ trên các token của câu trả lời:

$$L(\theta) = -\sum_{t \in a} \log p_\theta(a_t \mid I, q, a_{<t})$$

40.000 mẫu được lấy cân bằng theo loại câu (P1 dùng toàn bộ 3.543 câu, mỗi loại còn lại 5.208 câu), train 1 epoch = 2.500 bước. Để mô hình không lệ thuộc đủ 6 ảnh, mỗi camera không được câu hỏi nhắc tới bị bỏ với xác suất 0,15. Chi tiết siêu tham số ở Phụ lục A.

Baseline và đối chứng. B0 trả lời bằng đáp án phổ biến nhất trong train của cùng mẫu câu, không nhìn ảnh. B1 là SigLIP2 [8] zero-shot trên vùng cắt quanh thẻ. B2 là mô hình gốc zero-shot, và B2 few-shot được xem 2 câu trả lời mẫu. T là LoRA với công thức y hệt R1 nhưng không có ảnh. R2 ghép 6 ảnh thành lưới 3 × 2. D1/D4 dùng 10.000 mẫu với 1 hoặc 4 epoch; D×8 lặp câu rẽ 8 lần. A-front và A-name đánh giá checkpoint R1 khi chỉ có CAM_FRONT hoặc khi bỏ tên camera. Bảng ký hiệu đầy đủ ở Phụ lục B.

5. Giao thức đánh giá

Chỉ số. Với P1, thẻ dự đoán và thẻ đáp án trong cùng camera được ghép một–một bằng thuật toán Hungarian; một cặp đúng khi cách nhau không quá τ pixel (τ ∈ {50, 100, 200}, chính là 100). *Grounding* là tỷ lệ thẻ dự đoán nằm trong một box nuScenes. Một thẻ là *bịa* khi không nằm trong box nào, cách box gần nhất hơn 100 px, và không trùng thẻ đáp án nào; điều kiện cuối giữ cho đèn và biển báo đúng không bị phạt. P2o và P6 dùng macro-F1, P3 accuracy, P4 balanced accuracy, P5 F1 trên tập loại vật thể. Với P2 trên toàn val, báo cáo balanced accuracy và recall/precision của câu rẽ.

Độ bất định. Câu hỏi trong cùng scene tương quan với nhau, nên khoảng tin cậy 95% được tính bằng bootstrap 1.000 lần rút lại *cả scene*. So sánh hai mô hình dùng bootstrap ghép cặp: cả hai được chấm trên cùng tập scene rút ra mỗi lần, và một chênh lệch được coi là có thật khi khoảng tin cậy của hiệu không chứa 0. Nhiễu giữa các lần train được đo bằng 3 seed của R1; các so sánh ghép cặp dùng seed 0.

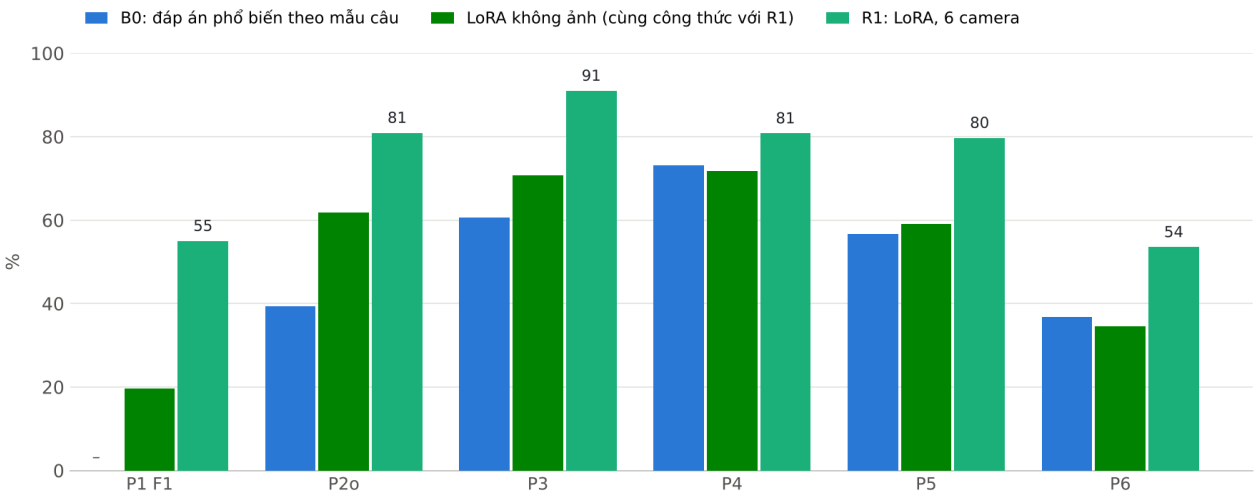
Kiểm định bộ chấm. Hàm chuẩn hoá *g* dựa trên từ khoá được kiểm tra tay trên 100 câu trả lời của R1 (20 câu mỗi loại P2o–P6): đúng 99/100; lỗi duy nhất ("Road sign") đã sửa trước khi tính mọi kết quả trong báo cáo.

6. Kết quả

Bảng 3. Kết quả chính trên 700 câu val cố định (%). R1: trung bình ± độ lệch chuẩn trên 3 seed; các dòng khác một lần chạy. Khoảng tin cậy 95% theo scene của từng ô rộng ±4 (P5) đến ±20 điểm (P6); đầy đủ ở Phụ lục C.

Mô hình	Ảnh	P1 F1	Bịa (%)	P2o	P3	P4	P5	P6
B0: đáp án phổ biến	–	–	–	39,4	60,7	73,1	56,7	36,9
B1: SigLIP2 zero-shot	vùng cắt	–	–	37,8	73,0	–	–	–
B2: Qwen3-VL-2B zero-shot	6	0,0	–	32,7	68,5	59,3	21,8	8,1
B2 few-shot	6	3,3	54,6	35,9	60,7	63,0	64,0	13,5
T: LoRA không ảnh	0	19,7	19,0	61,8	70,8	71,7	59,2	34,6
R2: LoRA, ảnh lưới	1 lưới	54,9	5,7	79,3	84,3	77,3	76,6	47,0
R1: LoRA, 6 ảnh (3 seed)	6	**54,7 ± 0,4**	**5,7 ± 1,0**	**81,8 ± 0,8**	**89,9 ± 1,1**	**80,8 ± 0,7**	**78,7 ± 1,4**	**53,9 ± 1,4**

R1 vượt mọi baseline ở P1, P2o, P3 và P5. Mô hình gốc không viết được thẻ đúng định dạng (P1 = 0, 16,7% câu trả lời không đọc được). Ba seed của R1 lệch nhau tối đa 2,7 điểm ở mọi chỉ số, nhỏ hơn nhiều khoảng tin cậy do tập val, nên nguồn bất định chính là cỡ mẫu đánh giá chứ không phải quá trình train.



Hình 2. B0, T (LoRA không ảnh) và R1 (seed 0) theo loại câu hỏi. Khoảng xanh lá → xanh ngọc là phần nhờ ảnh; xanh dương → xanh lá là phần học được chỉ từ câu chữ.

7. Phân tích

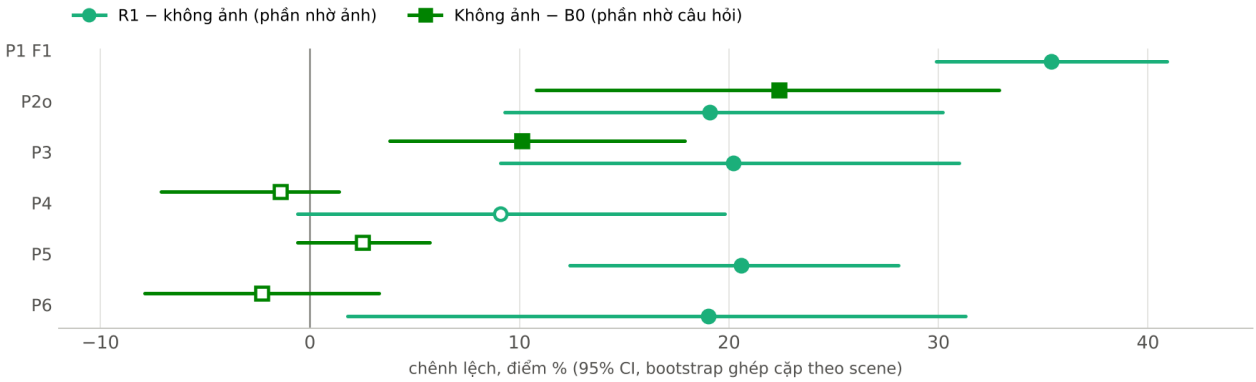
7.1 Ảnh đóng góp bao nhiêu?

Bảng 4. Phân rã mức tăng, bootstrap ghép cặp theo scene. In đậm: khoảng tin cậy không chứa 0.

Chênh lệch [95% CI]	P1 F1	Bịa	P2o	P3	P4	P5	P6
R1 − T (nhờ ảnh)	**+35,4** [+29,9; +40,9]	**−13,6** [−20,5; −7,5]	**+19,1** [+9,3; +30,2]	**+20,2** [+9,1; +31,0]	+9,1 [−0,6; +19,8]	**+20,6** [+12,4; +28,1]	**+19,0** [+1,8; +31,3]
T − B0 (nhờ câu chữ)	–	–	**+22,4** [+10,8; +32,9]	**+10,1** [+3,8; +17,9]	−1,4 [−7,1; +1,4]	+2,5 [−0,6; +5,7]	−2,3 [−7,9; +3,3]
R1 − B0 (tổng)	–	–	**+41,5** [+32,8; +49,4]	**+30,3** [+18,8; +42,2]	+7,7 [−3,8; +20,0]	**+23,0** [+14,4; +30,9]	+16,7 [−2,6; +31,1]

Phát hiện 1. Ảnh đóng góp +19 đến +35 điểm ở P1, P2o, P3, P5, P6 và giảm thẻ bịa 13,6 điểm. P4 là ngoại lệ (+9,1, khoảng tin cậy chứa 0): câu có/không theo vùng đã đoán khá tốt từ mẫu câu.

Phát hiện 2. Một phần đáng kể của mức tăng so với baseline không cần ảnh. Chỉ fine-tune trên chữ đã tăng P2o 22,4 điểm, khoảng một nửa mức tăng tổng của R1. So với B0 thôi thì sẽ đánh giá quá cao vai trò của ảnh; baseline đúng là cùng công thức train, không có ảnh.



Hình 3. Phần nhờ ảnh (R1 − T) và phần nhờ câu chữ (T − B0). Điểm tô đặc: khoảng tin cậy không chứa 0.

7.2 Mô hình có nhìn vào đúng camera không?

Bảng 5. Điểm trên các câu hỏi về camera không phải CAM_FRONT. Trên câu hỏi về CAM_FRONT, A-front giữ nguyên điểm của R1 (P3 87,0; P4 95,8).

Câu hỏi về 5 camera khác CAM_FRONT	P1 F1	P2o	P3	P5	P6
R1, đủ 6 camera	51,9	88,2	95,3	78,6	58,3
A-front: R1, chỉ CAM_FRONT	0,0	61,6	51,2	60,9	36,6
T: LoRA không ảnh	21,3	58,4	74,4	53,1	37,1

Phát hiện 3. R1 dùng ảnh của chính camera được hỏi. Khi chỉ còn CAM_FRONT, điểm trên câu hỏi về các camera khác tụt 18–44 điểm, về gần mức của mô hình không ảnh, còn điểm trên câu hỏi về CAM_FRONT không đổi. Bỏ tên camera khỏi prompt thì P1 về 0 vì mô hình không viết được phần CAM_... của thẻ; vì R1 luôn được train có tên camera, điều này cho thấy R1 dựa vào tên camera chứ chưa chứng minh tên camera là bắt buộc.

7.3 Định vị hay định dạng?

Phát hiện 4. Fine-tune học định vị, không chỉ học định dạng. Với 2 câu trả lời mẫu, mô hình gốc học được cách trả lời (câu không đọc được giảm từ 16,7% xuống 4,6%, P5 tăng từ 21,8 lên 64,0) nhưng P1 chỉ đạt 3,3 với 54,6% thẻ bịa. Trong P1 F1 của R1, khoảng 20 điểm đạt được cả khi không có ảnh (đoán vị trí hay gặp) và khoảng 35 điểm đến từ việc nhìn ảnh.

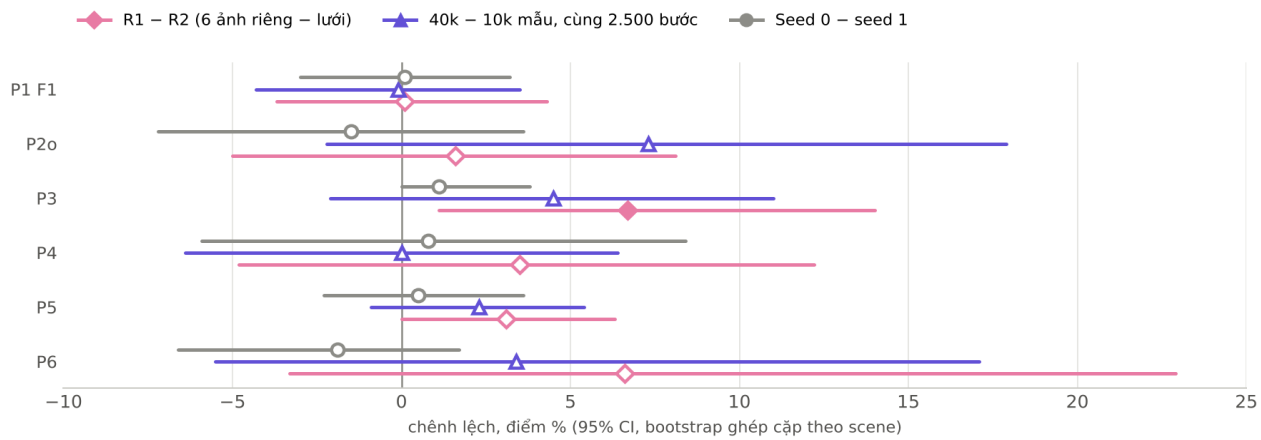
7.4 Lựa chọn thiết kế

Bảng 6. So sánh thiết kế, bootstrap ghép cặp theo scene.

Chênh lệch [95% CI]	P1 F1	P2o	P3	P4	P5	P6
R1 − R2 (6 ảnh − lưới)	+0,1 [−3,7; +4,3]	+1,6 [−5,0; +8,1]	**+6,7** [+1,1; +14,0]	+3,5 [−4,8; +12,2]	+3,1 [−0,0; +6,3]	+6,6 [−3,3; +22,9]
40k − 10k mẫu, cùng 2.500 bước	−0,1 [−4,3; +3,5]	+7,3 [−2,2; +17,9]	+4,5 [−2,1; +11,0]	+0,0 [−6,4; +6,4]	+2,3 [−0,9; +5,4]	+3,4 [−5,5; +17,1]
10k: 2.500 − 625 bước	**+5,4** [+1,3; +9,3]	+3,4 [−6,6; +14,9]	+1,1 [−5,1; +6,7]	+0,6 [−9,2; +10,4]	+0,6 [−3,2; +4,2]	+0,2 [−14,8; +17,0]
Seed 0 − seed 1	+0,1 [−3,0; +3,2]	−1,5 [−7,2; +3,6]	+1,1 [+0,0; +3,8]	+0,8 [−5,9; +8,4]	+0,5 [−2,3; +3,6]	−1,9 [−6,6; +1,7]

Phát hiện 5. Không phải thêm dữ liệu mà là thêm bước train. Từ 10k lên 40k mẫu (cùng 1 epoch), P1 tăng 5,3 điểm; nhưng 10k mẫu × 4 epoch, cùng 2.500 bước, đạt đúng mức đó (55,1). Khi số bước bằng nhau, không chỉ số nào cho thấy tác động có ý nghĩa của lượng dữ liệu.

Phát hiện 6. Sáu ảnh riêng ngang ảnh lưới trừ ở P3 (+6,7; R2 đạt 84,3, dưới cả ba seed của R1), trong khi ảnh lưới tốn nhiều token hơn (630 so với 588), chậm hơn 10% khi suy luận và 20% khi train. Chúng tôi chọn 6 ảnh riêng có tên camera.



Hình 4. Các so sánh thiết kế. Điểm tô đặc: khoảng tin cậy không chứa 0.

7.5 Theo thành phố và điều kiện

Bảng 7. P1 theo nhóm (số câu P1 trong ngoặc).

P1 F1 / bịa (%)	Boston (59)	Singapore (41)	Ngày (69)	Đêm (11)	Mưa (20)
R1 seed 0	52,6 / 4,2	59,3 / 7,5	53,5 / 4,6	71,4 / 4,4	50,6 / 8,5
R1 seed 1	52,7 / 5,6	58,9 / 3,4	52,8 / 3,8	70,2 / 0,0	53,4 / 10,2
R1 seed 2	52,2 / 6,4	57,7 / 7,4	52,9 / 7,2	68,6 / 0,0	50,3 / 9,2
T: không ảnh	19,5 / 8,5	19,8 / 34,1	19,1 / 22,5	29,3 / 9,1	15,6 / 12,5

Singapore cao hơn Boston khoảng 6 điểm ở cả ba seed. Trời mưa có tỷ lệ thẻ bịa cao nhất (8,5–10,2%). Ban đêm có điểm cao nhất nhưng chỉ có 11 câu, nên chúng tôi không rút ra kết luận.

8. Giới hạn của một khung hình: chuyển động

Bảng 8. Câu hỏi rẽ trên toàn bộ 1.153 câu P2 val.

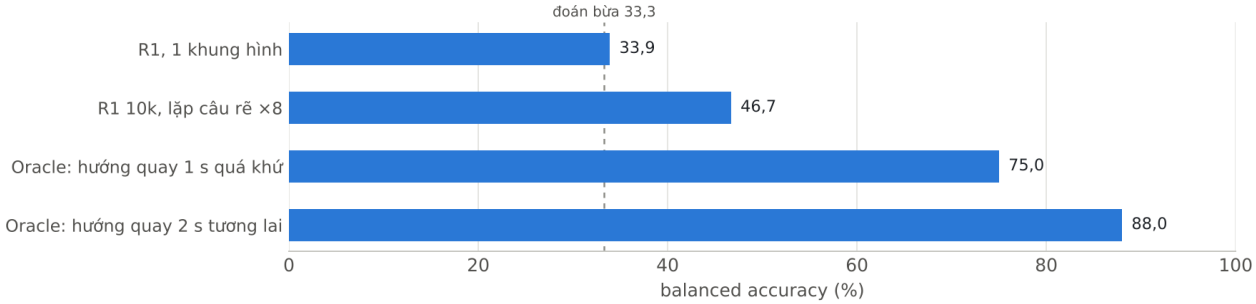
Toàn bộ P2 val (83 câu rẽ)	Accuracy	Balanced acc	Recall rẽ, đúng hướng	Recall rẽ, bất kỳ	Precision rẽ, bất kỳ	Tỷ lệ đoán rẽ
B0	92,8	33,3	0,0	0,0	–	0,0
R1	92,3	33,9	1,2	2,4	22,2	0,8
D×8: 10k, câu rẽ × 8	67,4	46,7	34,9	73,5	15,9	33,2

Không có oversample, mô hình gần như luôn trả lời "đi thẳng"; accuracy 92% che giấu điều đó. Lặp câu rẽ 8 lần giúp phát hiện "có rẽ" tốt hơn đoán bừa (bắt 73,5% câu rẽ khi chỉ đoán rẽ 33,2% số câu), nhưng hướng rẽ đúng ở 29/61 câu bắt được (48%), ngang tung đồng xu.

Oracle. Để biết thông tin nào giải thích được nhãn, chúng tôi tính thay đổi góc quay (yaw) của box nuScenes trong 1–3 giây trước và sau keyframe, và chấm một luật ngưỡng đơn giản (ngưỡng chọn trên train). Quá khứ và tương lai của cùng một khoảng thời gian được chấm trên cùng tập câu hỏi.

Bảng 9. Oracle trên hướng quay thật của box nuScenes.

Cửa sổ	Quá khứ: balanced acc	Tương lai: balanced acc	Ngưỡng (°) quá khứ / tương lai	Số câu val
1 giây	75,0	83,8	3 / 3	1.099
2 giây	74,9	88,0	5 / 7	835
3 giây	73,3	86,2	8 / 12	669



Hình 5. Balanced accuracy trên P2: mô hình một khung hình so với oracle.

Phát hiện 7. Nhãn rẽ của DriveLM phụ thuộc một phần vào tương lai: ở mọi cửa sổ, chuyển động tương lai giải thích nhãn tốt hơn chuyển động quá khứ 9–13 điểm. Một phần P2 thực chất là câu hỏi dự đoán.

Phát hiện 8. Chuyển động quá khứ đã chứa phần lớn thông tin cần thiết: hướng quay thật trong 1 giây vừa qua đạt 75,0, so với 33,9 của R1. Mô hình chỉ dùng camera phải tự ước lượng hướng quay từ ảnh, nên 75 là trần trên chứ chưa phải mức chắc đạt được. Khoảng cách này là lý do định lượng cho đầu vào nhiều khung hình.

9. Phân tích lỗi

- **Nhóm hỗn hợp (P6).** Khi đáp án là "vài xe đỗ, vài xe chạy" (7/20 câu trong mẫu kiểm tra tay), R1 luôn trả lời một trạng thái duy nhất và sai cả 7.
- **Bỏ sót vật thể hiếm (P5).** Trong 20 câu, R1 bỏ sót 15 loại vật thể và chỉ thêm sai 2: lỗi chủ yếu là recall, không phải ảo giác.
- **Sai số toạ độ (P1).** F1 tăng từ 44,5 lên 60,4 (trung bình 3 seed) khi nới ngưỡng từ 50 lên 200 px; ngưỡng 50 px nhỏ hơn nửa ô token.
- **Đỗ hay dừng tạm (P2o)** cần chuyển động để phân biệt; **SUV hay truck (P3)** trùng với chỗ hai bộ nhãn DriveLM và nuScenes cũng không thống nhất.

10. Chi phí

Bảng 10. Chi phí trên một RTX 5060 Ti 16 GB (bf16, batch 1, greedy).

	R1	R2	T	A-front	B2
Token ảnh	588	630	0	98	588
Latency p50 (s)	0,23	0,24	0,10	0,12	0,46
VRAM suy luận (GB)	4,2	4,2	4,1	4,1	4,1
Train, 2.500 bước (giờ)	4,2	5,0	1,7	–	–

Latency của R1 thấp hơn B2 dù cùng mô hình nền, vì R1 học kiểu trả lời ngắn của DriveLM. Ở mức 0,2 giây mỗi câu hỏi, mô hình phù hợp cho phân tích off-board; triển khai on-board cần đo tách prefill/decode, lượng tử hoá và trả lời nhiều câu hỏi trong một lần đọc ảnh.

11. Hạn chế

- 100 câu val mỗi loại cho khoảng tin cậy ±4–20 điểm; khác biệt nhỏ chỉ được nhận khi bootstrap ghép cặp ủng hộ. Ba seed chỉ có cho R1.
- Tập val tách theo scene nhưng chung bốn khu vực của nuScenes: đây là đánh giá trong phân phối. Qwen3-VL có thể đã thấy ảnh nuScenes khi pretrain; mọi bản so sánh dùng chung backbone nên so sánh nội bộ vẫn công bằng.
- Bộ chấm dựa trên từ khoá, được kiểm tra tay bởi chính tác giả, chưa có người chấm độc lập. Thẻ bịa là cận trên: biển báo có thật mà DriveLM không liệt kê bị tính là bịa.
- Ablation camera dùng lại checkpoint R1, chưa train riêng. Đánh giá là open-loop và không đo chất lượng lái.

12. Kết luận

Kiểm chứng câu trả lời bằng nhãn 3D thay vì so chữ cho phép đo những điều mà điểm benchmark thông thường che khuất. Một VLM 2B, fine-tune trong khoảng 4 giờ trên một GPU 16 GB, định vị được vật thể quan trọng với ít thẻ bịa và dùng ảnh của đúng camera. Nhưng một nửa mức tăng ở một số loại câu đến từ câu chữ, mức tăng tưởng như do dữ liệu là do số bước train, và chuyển động vẫn nằm ngoài tầm của một khung hình. Giai đoạn 2 (kế hoạch riêng) bổ sung khung hình quá khứ, nối perception với dự đoán và lập kế hoạch, và xuất quỹ đạo với baseline chỉ dùng trạng thái xe.

Tuyên bố về khả năng tái lập

Mỗi thí nghiệm có một config; mỗi run lưu config đã gộp, lệnh, commit và phiên bản thư viện. Mã nguồn gồm 43 test và một lần chạy đầu cuối trên dữ liệu tổng hợp đúng định dạng. `scripts/check_runs.py` xác nhận mọi run dùng cùng tập câu hỏi, đúng adapter, seed và số mẫu. `make verify` chạy lại toàn bộ phần chấm và đối chiếu 239 con số của báo cáo tóm tắt (239/239 khớp); các con số chỉ có trong báo cáo này được đối chiếu tay với cùng các bảng kết quả. Dữ liệu DriveLM (CC BY-NC-SA 4.0) và nuScenes không được phân phối lại; hướng dẫn tải ở README.

Tài liệu tham khảo

[1] C. Sima và cs. DriveLM: Driving with Graph Visual Question Answering. ECCV 2024.

[2] H. Caesar và cs. nuScenes: A multimodal dataset for autonomous driving. CVPR 2020.

[3] Z. Li và cs. Is Ego Status All You Need for Open-Loop End-to-End Autonomous Driving? CVPR 2024.

[4] X. Zhou và cs. OpenDriveVLA: Towards End-to-end Autonomous Driving with Large Vision Language Action Model. AAAI 2026.

[5] Qwen Team. Qwen3-VL. Mô hình Qwen3-VL-2B-Instruct.

[6] E. J. Hu và cs. LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.

[7] Z. Zhou và cs. AutoVLA: A Vision-Language-Action Model for End-to-End Autonomous Driving with Adaptive Reasoning and Reinforcement Fine-Tuning. NeurIPS 2025.

[8] M. Tschannen và cs. SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features. 2025.

[9] X. Tian và cs. DriveVLM: The Convergence of Autonomous Driving and Large Vision-Language Models. CoRL 2024.

[10] J.-J. Hwang và cs. EMMA: End-to-End Multimodal Model for Autonomous Driving. arXiv 2024.

[11] T. Qian và cs. NuScenes-QA: A Multi-modal Visual Question Answering Benchmark for Autonomous Driving Scenario. AAAI 2024.

[12] Y. Li và cs. Evaluating Object Hallucination in Large Vision-Language Models (POPE). EMNLP 2023.

Phụ lục A. Siêu tham số và cấu hình

Bảng 11. Siêu tham số của R1.

Thành phần	Giá trị
Mô hình nền	Qwen3-VL-2B-Instruct (2,14 tỷ tham số); encoder ảnh đóng băng
LoRA	r = 16, α = 32, dropout 0,05; q, k, v, o, gate, up, down của phần ngôn ngữ; 17.432.576 tham số (0,81%)
Tối ưu	AdamW, lr 2×10^{-4}, cosine, warmup 3% (75 bước); batch 1 × tích luỹ 16; bf16; gradient checkpointing
Dữ liệu train	40.000 mẫu cân bằng theo loại câu (P1 3.543, các loại khác 5.208); 1 epoch = 2.500 bước
Ảnh	Ngân sách 65.536–112.896 pixel mỗi camera (448 × 252); 98 token mỗi camera; tắt camera không được hỏi với xác suất 0,15
Sinh câu trả lời	Greedy, tối đa 256 token
Seed	Dữ liệu: 0 (cố định chia train/val và tập val). Train: 0, 1, 2

Cấu hình các thí nghiệm

Bảng 12. Mỗi config chỉ đổi một yếu tố so với R1. Chạy: make run EXP=<config>.

Config	Khác R1 ở	Mẫu train	Bước	Seed	Token ảnh
r1_6cam	–	40.000	2.500	0	588
r1_seed1 / r1_seed2	seed	40.000	2.500	1 / 2	588
r1_textonly	không ảnh, không tắt camera	40.000	2.500	0	0
r2_grid	1 ảnh lưới 3 × 2 (ngân sách pixel 6 lần)	40.000	2.500	0	630
r1_10k	10.000 mẫu	10.000	625	0	588
r1_10k_4ep	10.000 mẫu × 4 epoch	10.000	2.500	0	588
r1_10k_turnx8	10.000 mẫu, câu rẽ P2 lặp × 8 trước khi lấy mẫu	10.000	625	0	588
abl_front_only / abl_no_camname	checkpoint R1; chỉ CAM_FRONT / bỏ tên camera	–	–	0	98 / 588
b2_zeroshot / b2_fewshot	không train; few-shot: 2 câu trả lời mẫu mỗi loại	–	–	0	588
p2full_*	P2 trên toàn bộ 1.153 câu val	–	–	0	–

Phụ lục B. Ký hiệu và thuật ngữ

Mô hình và thí nghiệm (tên config trong repo đặt trong ngoặc)

Ký hiệu	Ý nghĩa	Vai trò
B0	Baseline 0 (`b0_prior`): không nhìn ảnh, trả lời bằng đáp án phổ biến nhất trong tập train của cùng mẫu câu hỏi (thẻ vật thể thay bằng <obj>); mẫu câu chưa gặp thì lấy đáp án phổ biến của loại câu	Mức điểm đạt được mà không cần nhìn
B1	Baseline 1 (`b1_siglip`): SigLIP2 zero-shot, so vùng cắt 320 × 320 px quanh thẻ trong câu hỏi với các nhãn ứng viên; chỉ trả lời được P2, P2o, P3	Bộ mã hoá ảnh mạnh nhưng không sinh chữ
B2	Baseline 2 (`b2_zeroshot`): Qwen3-VL-2B-Instruct gốc, không fine-tune, nhận đủ 6 ảnh	Mô hình gốc làm được bao nhiêu
B2 few-shot	B2 được xem thêm 2 câu trả lời mẫu cùng loại câu hỏi, chỉ dạng chữ (`b2_fewshot`)	Tách phần "học định dạng" khỏi phần "học nhìn"
T	Text-only (`r1_textonly`): LoRA giống hệt R1 (40.000 mẫu, 2.500 bước) nhưng bỏ hết ảnh	Tách phần nhờ ảnh khỏi phần nhờ câu hỏi
R1	Mô hình chính (`r1_6cam`): Qwen3-VL-2B + LoRA, 6 ảnh camera riêng có tên, 40.000 mẫu, 1 epoch, tắt ngẫu nhiên 15% camera không được hỏi	Kết quả chính của giai đoạn 1
R1 seed 0 / 1 / 2	R1 train lại với seed 0, 1, 2 (`r1_6cam`, `r1_seed1`, `r1_seed2`); "R1" không ghi seed nghĩa là seed 0	Đo nhiễu giữa các lần train
R2	R1 nhưng ghép 6 ảnh thành một ảnh lưới 3 × 2, cùng độ phân giải mỗi ô (`r2_grid`)	So cách đưa nhiều camera vào
D1	R1 với 10.000 mẫu × 1 epoch = 625 bước (`r1_10k`)	Ít dữ liệu, ít bước
D4	R1 với 10.000 mẫu × 4 epoch = 2.500 bước, bằng số bước của R1 (`r1_10k_4ep`)	Tách tác động của dữ liệu khỏi số bước
D×8	D1 nhưng câu rẽ của P2 được lặp 8 lần trước khi lấy mẫu (`r1_10k_turnx8`)	Thử khắc phục mất cân bằng câu rẽ
A-front	Ablation: checkpoint R1, khi đánh giá chỉ đưa ảnh CAM_FRONT (`abl_front_only`)	Mô hình có dùng ảnh của đúng camera không
A-name	Ablation: checkpoint R1, khi đánh giá bỏ tên camera khỏi prompt (`abl_no_camname`)	Mô hình có dựa vào tên camera không
Oracle	Luật ngưỡng trên thay đổi góc quay thật của box nuScenes trong 1–3 giây quá khứ hoặc tương lai; không phải mô hình học máy	Trần trên cho câu hỏi rẽ (P2)
p2full_*	Các mô hình trên chấm lại P2 trên toàn bộ 1.153 câu val thay vì 100	Đủ câu rẽ (83) để đo

Loại câu hỏi

Ký hiệu	Câu hỏi	Câu trả lời mong đợi
P1	Vật thể quan trọng trong cảnh	Danh sách thẻ <c, CAMERA, x, y>
P2	Trạng thái di chuyển của một vật thể (moving status)	Đi thẳng / rẽ trái / rẽ phải
P2o	Trạng thái quan sát của một vật thể (observed status; o = observed)	Đang chạy / đứng yên
P3	Mô tả hình ảnh của một vật thể	Câu mô tả; chấm theo loại vật thể suy ra (car, truck, pedestrian, ...)
P4	Có loại vật thể X với trạng thái Y ở vùng Z không?	Có / không
P5	Những vật thể nào ở vùng Z?	Danh sách loại vật thể
P6	Trạng thái của các vật thể loại X ở vùng Z	Đang chạy / đỗ / đứng / có hoặc không có người lái, có thể hỗn hợp
Thẻ <c, CAM, x, y>	Cách DriveLM chỉ một vật thể: mã vật thể, tên camera, toạ độ tâm (pixel) trên ảnh gốc 1600 × 900 của camera đó	
Vùng	front, front left, front right, back, back left, back right; mỗi vùng tương ứng một camera (front left → CAM_FRONT_LEFT)	

Chỉ số và thuật ngữ

Ký hiệu	Ý nghĩa
τ (tau)	Ngưỡng khoảng cách (pixel, ảnh gốc) để một thẻ dự đoán được tính là trùng thẻ đáp án; dùng τ = 50, 100, 200 px, chính là 100
Precision / Recall / F1	Tỷ lệ thẻ (hoặc loại vật thể) dự đoán là đúng / tỷ lệ đáp án được tìm ra / trung bình điều hoà của hai tỷ lệ
Ghép Hungarian	Ghép một–một giữa thẻ dự đoán và thẻ đáp án sao cho tổng khoảng cách nhỏ nhất, trước khi áp ngưỡng τ
Grounding	Tỷ lệ thẻ dự đoán nằm trong một box nuScenes bất kỳ (mô hình chỉ vào chỗ có vật thể thật)
Bịa (hallucination)	Tỷ lệ thẻ dự đoán không nằm trong box nào, cách box gần nhất hơn 100 px, và không trùng thẻ đáp án nào
Accuracy	Tỷ lệ câu trả lời đúng
Macro-F1	Trung bình F1 của từng nhãn, mỗi nhãn nặng như nhau; không bị nhãn phổ biến lấn át
Balanced accuracy	Trung bình recall của từng nhãn; đoán bừa với 3 nhãn cho 33,3, với 2 nhãn cho 50
Recall / precision câu rẽ	Tỷ lệ câu rẽ thật được đoán là rẽ / tỷ lệ câu bị đoán là rẽ mà đúng là rẽ; "đúng hướng" đòi đúng cả trái/phải, "bất kỳ" thì không
Không đọc được	Tỷ lệ câu trả lời mà bộ chấm không rút ra được nhãn (parse-fail)
Collapse	Mô hình trả lời cùng một đáp án cho mọi câu của một loại
95% CI [a; b]	Khoảng tin cậy 95%: tính bằng bootstrap 1.000 lần, mỗi lần rút lại cả scene có hoàn lại
Bootstrap ghép cặp	So hai mô hình trên cùng các câu hỏi: mỗi lần rút lại scene, tính hiệu A − B; chênh lệch có thật khi khoảng tin cậy của hiệu không chứa 0
Tập "sạch"	Các câu mà nhãn DriveLM không mâu thuẫn nhãn nuScenes (bỏ các câu đánh dấu nusc_disagree)
Scene / keyframe	Scene: một đoạn lái khoảng 20 giây của nuScenes; keyframe: thời điểm có nhãn 3D (2 lần mỗi giây), mỗi keyframe có 6 ảnh camera
LoRA, r, α	Fine-tune bằng ma trận hạng thấp gắn vào mô hình gốc (đóng băng); r là hạng, α là hệ số tỷ lệ
Mẫu, epoch, bước	Mẫu: một cặp câu hỏi–trả lời. Epoch: một lượt qua toàn bộ mẫu train. Bước: một lần cập nhật trọng số (16 mẫu)
10k / 40k	10.000 / 40.000 mẫu train
Seed	Số khởi tạo bộ sinh số ngẫu nhiên (chọn mẫu, thứ tự, camera bị tắt, khởi tạo LoRA)
Token ảnh	Số đơn vị đầu vào mà ảnh chiếm trong mô hình; mỗi camera 98 token, mỗi token phủ khoảng 115 × 130 px ảnh gốc
Latency p50	Thời gian trả lời một câu hỏi, giá trị trung vị (50% câu nhanh hơn)
Open-loop	Đánh giá trên dữ liệu đã ghi sẵn, đầu ra của mô hình không tác động lại cảnh

Phụ lục C. Khoảng tin cậy và nhãn sạch

Bảng 13. Khoảng tin cậy 95%, bootstrap theo scene (1.000 lần).

Mô hình	P1 F1	Bịa	P2o	P3	P4	P5	P6
B0	–	–	39,4 [34,8; 42,7]	60,7 [49,0; 71,3]	73,1 [63,5; 81,9]	56,7 [50,1; 63,4]	36,9 [28,7; 52,5]
B2 zero-shot	0,0	–	32,7 [22,0; 43,5]	68,5 [58,3; 78,5]	59,3 [48,2; 69,8]	21,8 [15,3; 28,5]	8,1 [4,6; 13,8]
B2 few-shot	3,3 [1,5; 5,7]	54,6 [43,3; 66,7]	35,9 [26,1; 45,6]	60,7 [49,4; 71,3]	63,0 [51,6; 73,7]	64,0 [59,1; 68,9]	13,5 [8,2; 23,0]
T: không ảnh	19,7 [14,8; 24,6]	19,0 [12,1; 26,7]	61,8 [51,6; 71,4]	70,8 [60,6; 80,9]	71,7 [62,2; 80,6]	59,2 [53,1; 65,3]	34,6 [25,8; 50,6]
R1 seed 0	55,0 [50,0; 59,5]	5,4 [3,3; 7,8]	80,9 [72,7; 88,5]	91,0 [85,2; 96,6]	80,8 [71,4; 89,3]	79,7 [75,4; 83,3]	53,6 [35,6; 76,5]
R1 seed 1	54,9 [50,2; 59,7]	4,8 [2,6; 7,3]	82,4 [73,4; 90,3]	89,9 [83,3; 95,5]	80,0 [69,4; 89,1]	79,3 [74,0; 84,0]	55,4 [37,3; 78,1]
R1 seed 2	54,2 [49,9; 58,7]	6,8 [4,7; 9,2]	82,2 [73,3; 90,2]	88,8 [82,3; 94,6]	81,5 [71,8; 89,9]	77,1 [73,5; 80,4]	52,7 [34,9; 75,2]
R2	54,9 [49,6; 59,8]	5,7 [3,2; 8,9]	79,3 [70,0; 87,8]	84,3 [75,0; 92,2]	77,3 [66,5; 87,8]	76,6 [72,1; 80,8]	47,0 [33,1; 70,2]
D4: 10k × 4	55,1 [50,2; 60,2]	5,4 [3,0; 7,6]	73,6 [62,8; 83,5]	86,5 [78,1; 93,3]	80,8 [70,9; 89,8]	77,4 [73,0; 81,4]	50,1 [33,1; 73,7]

Bảng 14. Điểm trên toàn bộ câu và trên tập "sạch" (bỏ câu có nhãn DriveLM mâu thuẫn nuScenes). Thứ hạng không đổi.

Mô hình	P2 acc: tất cả / sạch	P2o acc: tất cả / sạch	P4 b-acc: tất cả / sạch	P3: theo DriveLM / theo nuScenes
B0	91,0 / 90,1	65,0 / 65,9	73,1 / 74,9	60,7 / 64,4
T: không ảnh	91,0 / 90,1	64,0 / 64,8	71,7 / 72,8	70,8 / 72,4
R1 seed 0	90,0 / 89,0	83,0 / 84,6	80,8 / 81,1	91,0 / 92,0
R1 seed 1	91,0 / 90,1	84,0 / 83,5	80,0 / 79,7	89,9 / 90,8
R1 seed 2	90,0 / 89,0	84,0 / 84,6	81,5 / 81,1	88,8 / 89,7
R2	89,0 / 87,9	82,0 / 83,5	77,3 / 76,9	84,3 / 85,1

Phụ lục D. Điểm theo camera được hỏi

Bảng 15. "Trước" = câu hỏi về CAM_FRONT, "khác" = 5 camera còn lại (P4: 27 / 73 câu).

Mô hình	P2o trước / khác	P3 trước / khác	P4 trước / khác	P5 trước / khác	P6 trước / khác
B0	40,5 / 38,4	58,7 / 62,8	79,2 / 72,3	69,4 / 52,0	43,8 / 38,6
T: không ảnh	55,5 / 58,4	67,4 / 74,4	79,2 / 70,9	73,3 / 53,1	28,2 / 37,1
R1 seed 0	70,0 / 88,2	87,0 / 95,3	95,8 / 78,5	83,0 / 78,6	59,5 / 58,3
R1 chỉ CAM_FRONT	66,4 / 61,6	87,0 / 51,2	95,8 / 71,3	84,1 / 60,9	59,5 / 36,6
R1 bỏ tên camera	75,5 / 78,8	82,6 / 74,4	95,8 / 67,1	76,9 / 71,1	58,7 / 38,6
R2	68,3 / 86,1	82,6 / 86,1	95,8 / 74,7	78,5 / 76,0	56,8 / 39,9

Phụ lục E. Lệnh tái lập

`make data` (dựng dữ liệu, kiểm tra nhãn) → `make run EXP=<config>` (train, suy luận, chấm) → `make paired` (so sánh ghép cặp) → `make label-oracle` (oracle nhãn rẽ) → `make tables` → `make verify` (kiểm tra mọi con số của báo cáo, khoảng 10 phút, chỉ CPU). Dữ liệu DriveLM (CC BY-NC-SA 4.0) và nuScenes (điều khoản phi thương mại) không nằm trong repo; hướng dẫn tải ở README.